iDATA
Advanced analytics for business

PRESENTA A

BANCO DE DESARROLLO DE AMÉRICA LATINA

DOCUMENTO TÉCNICO Y DE ARQUITECTURA - VINCULADOR DMAF

Versión	a
1.0.0	2/2024

Nombre del cliente	CAF (Corporación Andina de Fomento)
Nombre del proyecto	Vinculador DMAF
Responsable IDATA	Felipe Taborda (Data Science) Daniela Osorio Trujillo (Project Analyst) Dany Daniel Carrillo (Senior Full Stack) Diego Alejandro Barrera (Tech Lead)
Cargo – correo	diego.barrera@idata.global

Contenido

1 Introducción 4
2 Objetivos 4
2.0 Generales 4

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

2.1 Específicos 4
3 Descripción del proyecto 4
3.0 Descripción 4
3.1 Requerimientos 4
4 Arquitectura de la solución 5
4.0 Diagrama lógico de arquitectura ..... **¡Error! Marcador no definido.**
4.1 Diagrama físico de arquitectura 5
4.1.0 Descripción de componentes 5
4.2 Ambientes disponibles 13
4.3 Estrategia conexión a fuentes de datos ..... **¡Error! Marcador no definido.**
4.3.0 Estrategia integration Runtime o VPN ..... **¡Error! Marcador no definido.**
4.4 Estrategia de logs y monitoreo 14
5 Matriz de roles ..... **¡Error! Marcador no definido.**
6 Azure DevOps 15

USA *333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131*
USA *1240 W Peachtree St NW, Atlanta, GA 30309*
Colombia *Medellín - Calle 67 # 52-20 Torre A INT 3015*
Centroamérica y el Caribe *RD Santo Domingo - Av. Lope de Vega 19 10119*
Chile *Santiago - Camino El Alba 9500 Of 303*

1 Introducción

Este documento tiene como objetivo dar a conocer la arquitectura diseñada para la iniciativa Vinculador.

2 Objetivos

2.0 Generales

El objetivo general de este documento es proveer información relevante sobre la arquitectura y el diseño de la solución desarrollada para conocer diferentes aspectos del sistema.

2.1 Específicos

- Describir detalladamente la arquitectura a nivel de servicios usados.
- Brindar una descripción funcional de los componentes de la arquitectura propuesta.
- Exponer la distribución de los diferentes componentes para ambientes de desarrollo y producción dentro de los diferentes componentes Microsoft Azure propuestos.
- Detallar los elementos de seguridad para cada uno de los servicios involucrados en la arquitectura.
- Definir la estrategia de integración y despliegue continuo.

3 Descripción del proyecto

3.0 Descripción

El proyecto vinculador DMAF, se centra en identificar de forma automática cuales proyectos son candidatos a ser cofinanciados por los diferentes aliados, además, reduce considerablemente el tiempo de análisis.

3.1 Requerimientos

- El cliente tiene la necesidad de cargar documentos de proyectos y aliados existentes o nuevos.
- El cliente tiene la necesidad de visualizar los documentos de proyectos y aliados que ya fueron cargar.
- El cliente tiene la necesidad de poder eliminar los documentos de proyectos y aliados.
- El cliente tiene la necesidad de procesar análisis entre los diferentes proyectos y aliados existentes, para poder conocer si los proyectos y aliados cumplen con las condiciones indicados por el negocio.

USA *333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131*
USA *1240 W Peachtree St NW, Atlanta, GA 30309*
Colombia *Medellín - Calle 67 # 52-20 Torre A INT 3015*
Centroamérica y el Caribe *RD Santo Domingo - Av. Lope de Vega 19 10119*
Chile *Santiago - Camino El Alba 9500 Of 303*

4 Arquitectura de la solución

El esquema de arquitectura que se presenta a continuación muestra un alcance inicial de referencia que cubre las necesidades actuales de los requerimientos de arquitectura con buenas prácticas, escalabilidad y costos.

4.0 Diagrama físico de arquitectura

El siguiente esquema representa la arquitectura implementada para el desarrollo del proyecto:

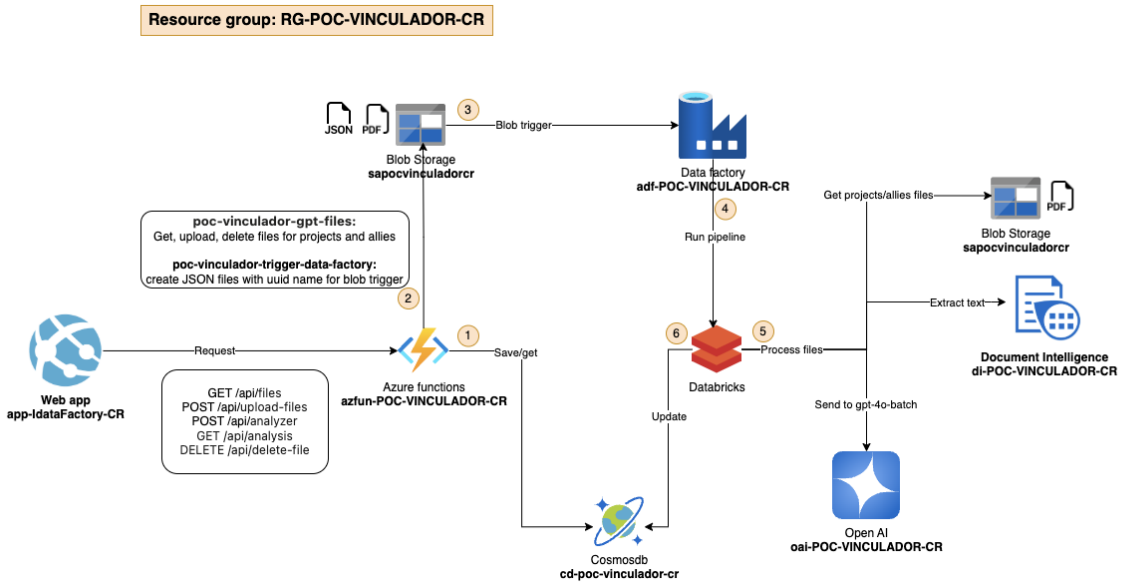

4.0.0 Descripción de componentes

Azure web application: Es un servicio de plataforma como servicio (PaaS), permite implementar, alojar y escalar aplicaciones web de manera sencilla y eficiente. Está diseñado para admitir múltiples lenguajes, marcos y entornos, incluyendo .NET, Java, Python, PHP, Node.js y Ruby.

Estamos utilizando una web app para poder alojar el backoffice que contiene todas las iniciativas, debido a su simplicidad a la hora de crear aplicaciones web dinámicas con una escalabilidad global.

Enlace del portal: https://app-idatafactory-cr.azurewebsites.net/

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

- Home page donde se muestran todas las iniciativas:

- Pantalla donde muestra un botón “Cargar documentos” para redireccionar a la **pantalla de documentos** donde se pueden cargar los documentos, un botón “Correr modelo” para poder enviar la solicitud de análisis al modelo, una tabla donde se lista todas solicitudes que se enviaron al modelo al presionar el botón “Correr modelo”, cada solicitud que se encuentra en estado “Finalizado” cuenta con la opción “Ver resultado” el cual redirecciona a la **pantalla de resultado de análisis.**

USA *333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131*
USA *1240 W Peachtree St NW, Atlanta, GA 30309*
Colombia *Medellín - Calle 67 # 52-20 Torre A INT 3015*
Centroamérica y el Caribe *RD Santo Domingo - Av. Lope de Vega 19 10119*
Chile *Santiago - Camino El Alba 9500 Of 303*

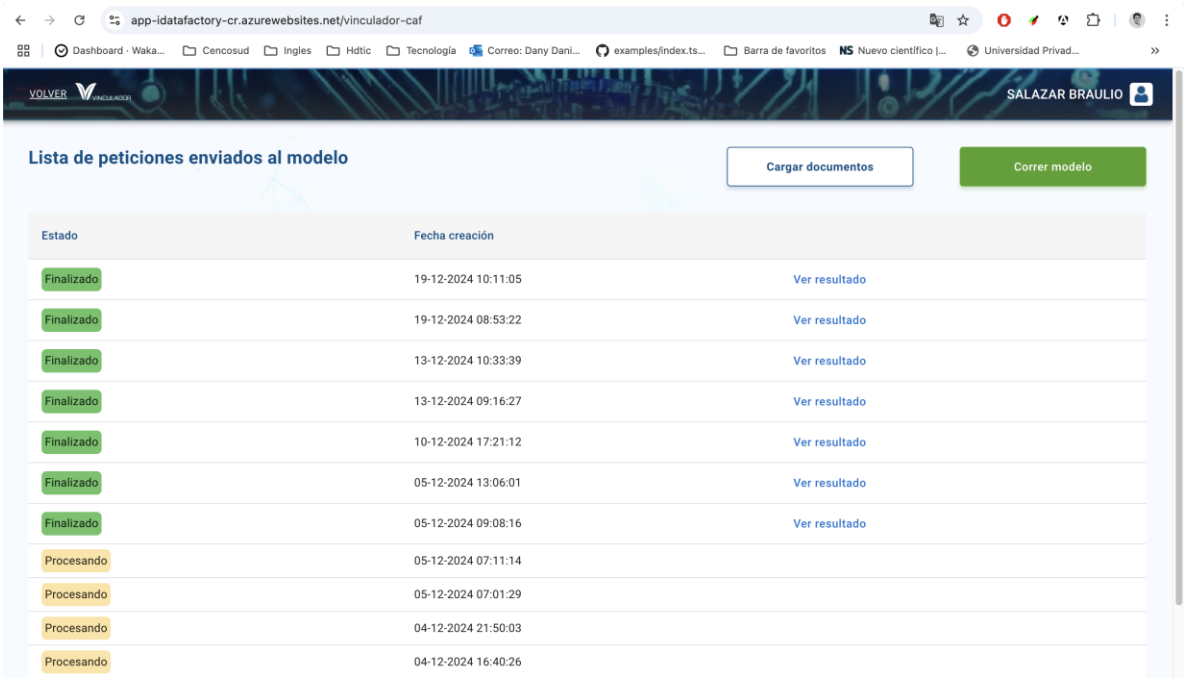

- **Pantalla de documentos:** El usuario puede realizar la carga de documentos para proyectos, aliados existentes o nuevos, además, se muestra la lista de documentos cargados por proyectos y aliados:

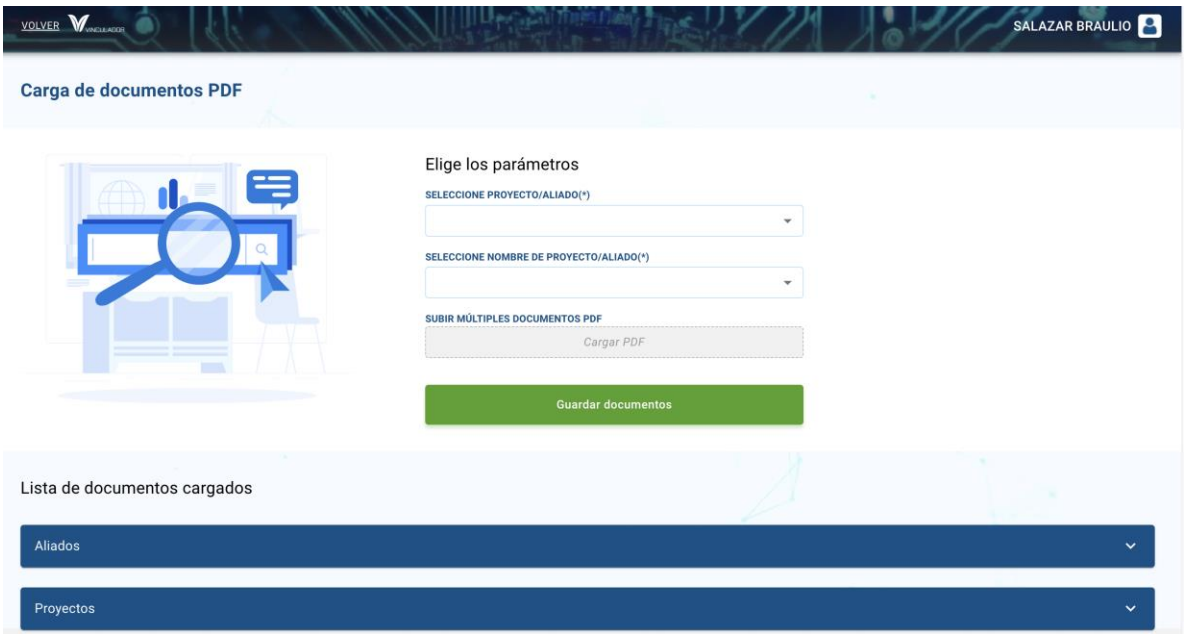

- **Pantalla de resultado de análisis:** Se muestra una tabla con el resultado del análisis de proyectos versus aliados realizados por el modelo, además, se muestra un botón para que el usuario pueda exportar la tabla en un archivo excel:

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

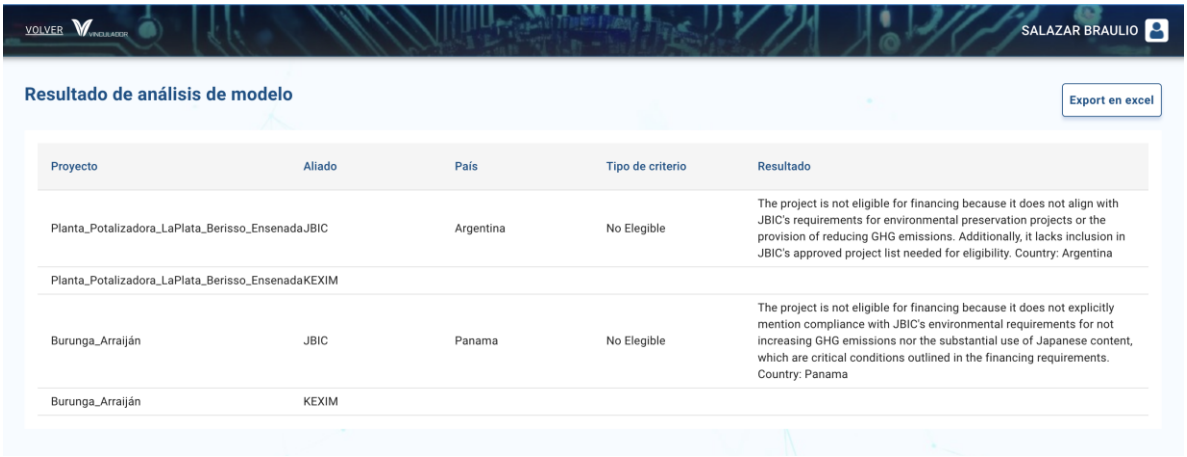

Proyecto	Aliado	País	Tipo de criterio	Resultado
Planta_Potalizadora_LaPlata_Berisso_Ensenada	JBIC	Argentina	No Elegible	The project is not eligible for financing because it does not align with JBIC's requirements for environmental preservation projects or the provision of reducing GHG emissions. Additionally, it lacks inclusion in JBIC's approved project list needed for eligibility. Country: Argentina
Planta_Potalizadora_LaPlata_Berisso_Ensenada	KEXIM			
Burunga_Arraiján	JBIC	Panama	No Elegible	The project is not eligible for financing because it does not explicitly mention compliance with JBIC's environmental requirements for not increasing GHG emissions nor the substantial use of Japanese content, which are critical conditions outlined in the financing requirements. Country: Panama
Burunga_Arraiján	KEXIM			

Azure functions: Es un servicio de **computación sin servidor** (serverless), diseñado para ejecutar pequeñas piezas de código, **conocidas como funciones,** en respuesta a eventos. Es ideal para ejecutar tareas ligeras y de corta duración sin necesidad de gestionar servidores o infraestructura subyacente.

Aprovechamos el potencial de los serverless con azure functions para desarrollar los servicios REST que permitan subir documentos hacia un contenedor, listar directorios y documentos de un contenedor, eliminar documentos, enviar a procesar análisis de proyectos y aliados:

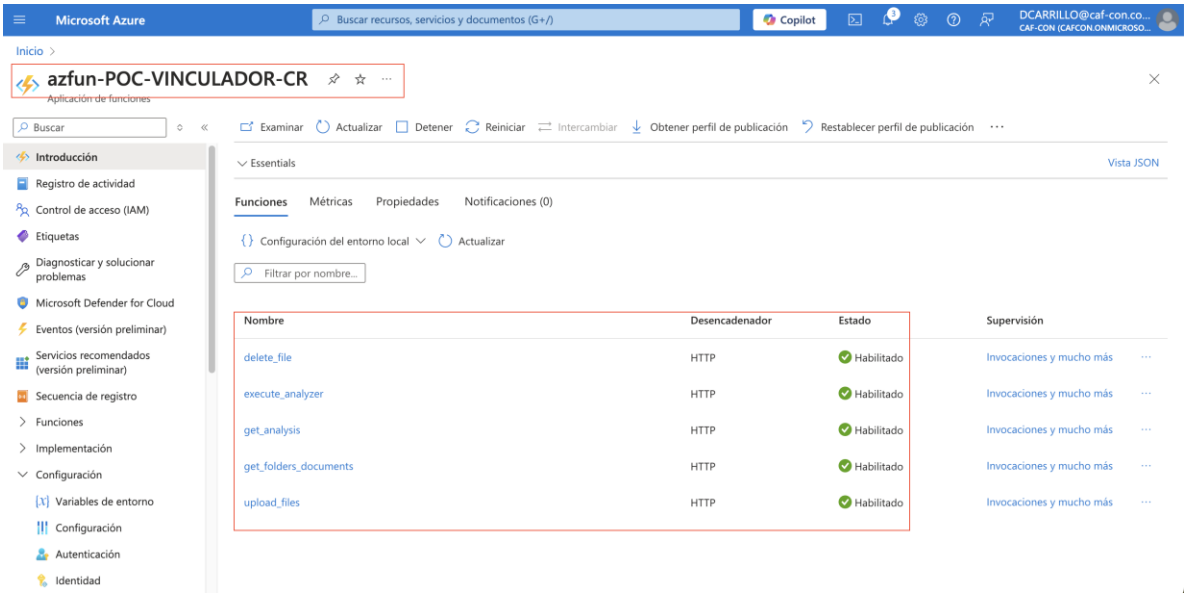

Azure cosmosdb: Es un servicio de base de datos NoSQL distribuido globalmente. Está diseñado para ser altamente disponible, escalable y rápido, ofreciendo compatibilidad con múltiples modelos de datos (documentos, clave-valor, columnares y grafos) y soporte para APIs populares como MongoDB, Cassandra, Gremlin, Table y Core (SQL).

USA *333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131*
USA *1240 W Peachtree St NW, Atlanta, GA 30309*
Colombia *Medellín - Calle 67 # 52-20 Torre A INT 3015*
Centroamérica y el Caribe *RD Santo Domingo - Av. Lope de Vega 19 10119*
Chile *Santiago - Camino El Alba 9500 Of 303*

En la arquitectura nos permite gestionar el proceso de análisis de proyectos y aliados de forma asíncrona, ya que se crea una petición para luego ser actualizado cuando termine el proceso de análisis:

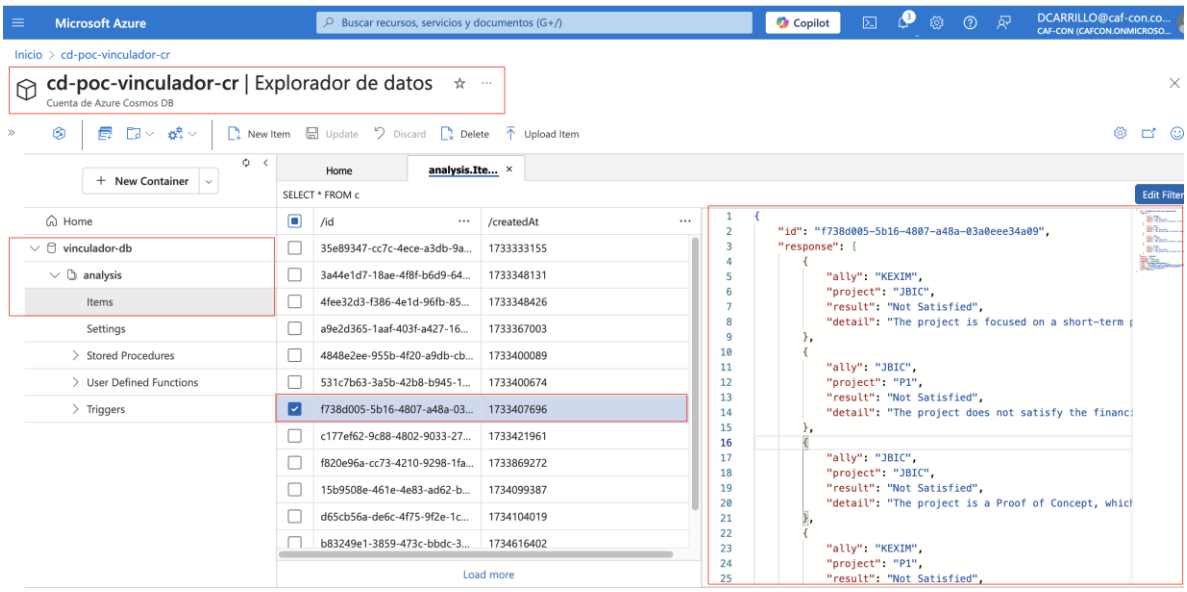

Azure blob storage: Es un servicio de almacenamiento de objetos en la nube. Está diseñado para almacenar grandes cantidades de datos no estructurados, como documentos, imágenes, videos, copias de seguridad, registros, y más.

Permite almacenar los documentos de proyectos y aliados, almacena los documentos de tipo JSONL para que luego sean enviados a openAI en modo batch, además, aprovechamos el blob trigger para poder enviar un evento hacia data factory:

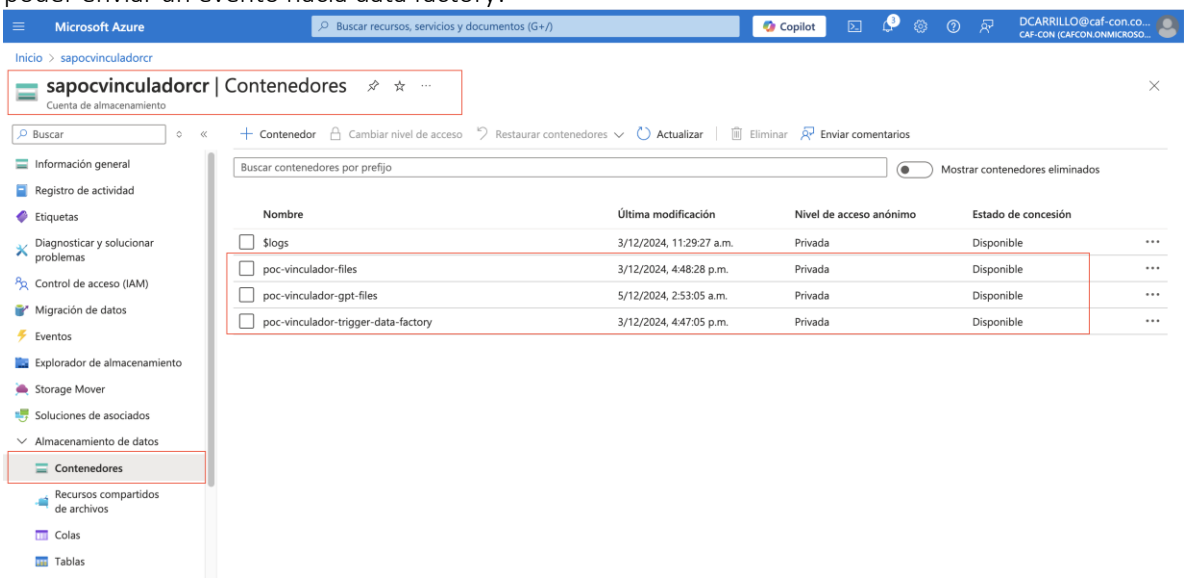

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

Azure data factory: Es un servicio de integración de datos en la nube. Es una herramienta que permite mover, transformar y orquestar grandes volúmenes de datos desde diversas fuentes hacia destinos definidos, facilitando la creación de flujos de trabajo de integración de datos (ETL/ELT).

En la arquitectura permite realizar una conexión hacia un notebook de databricks a través de un pipeline, el cual es ejecutado con un blob trigger cada vez que llegue un documento al contenedor, cuando el pipeline es ejecutado se envían los parametros necesarios a databricks para que siga el flujo:

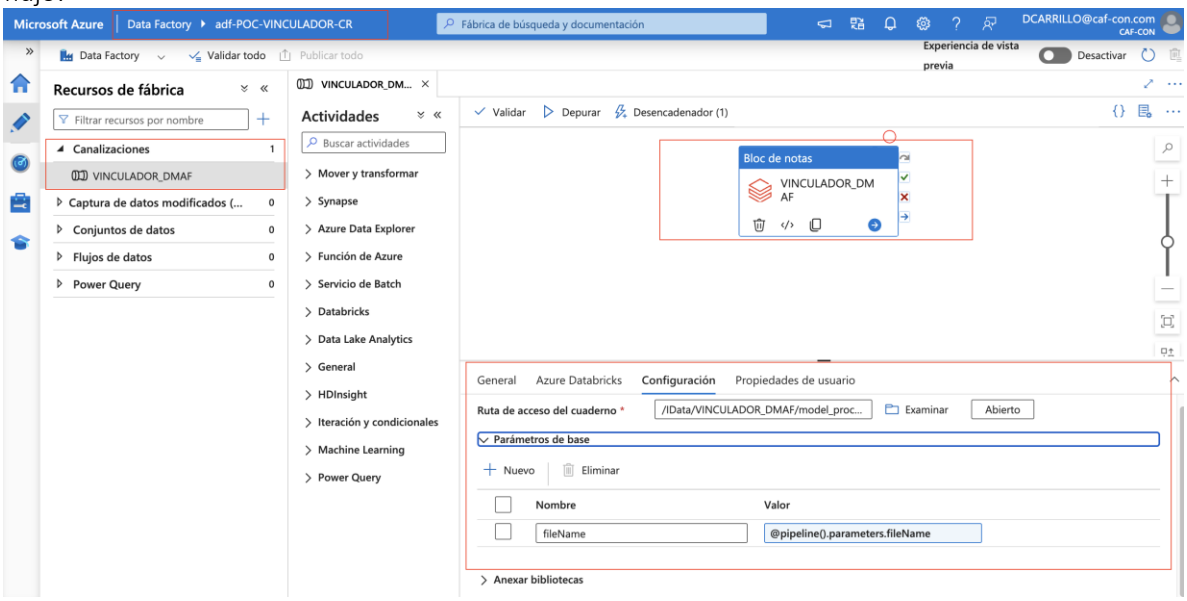

Azure document intelligence: Es un servicio de inteligencia artificial diseñado para extraer información estructurada y procesable de documentos no estructurados, como formularios, facturas, recibos y contratos. Utiliza capacidades avanzadas de machine learning para analizar y comprender documentos de manera eficiente.

En la arquitectura, permite extraer el contenido de los documentos de todos los proyectos y aliados de forma fácil:

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

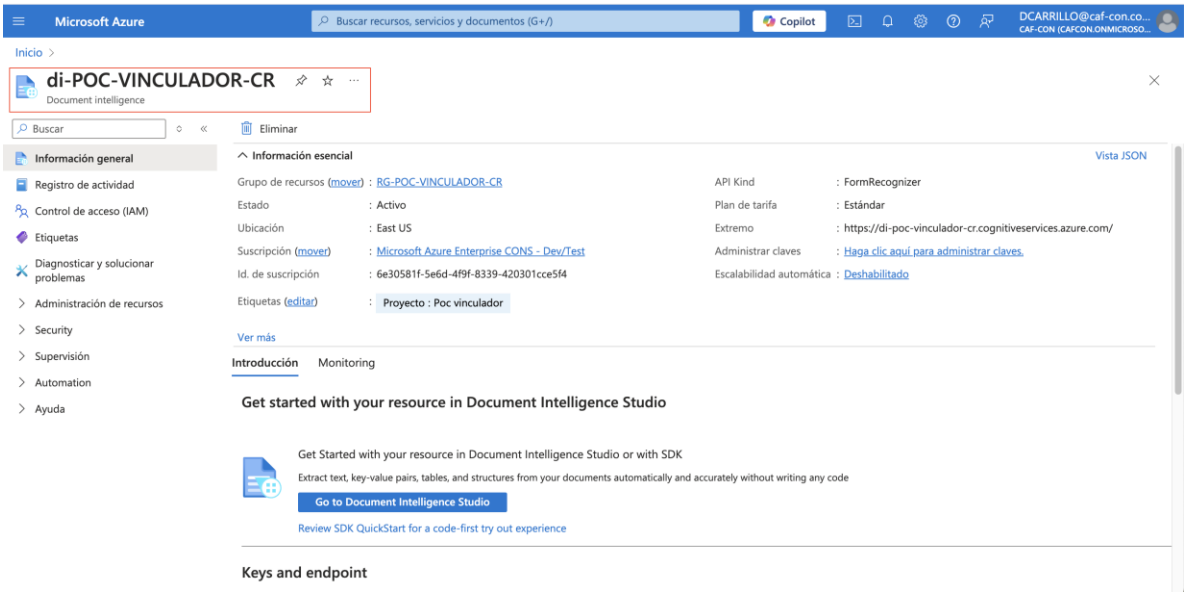

Azure openAI: Es un servicio que proporciona acceso a los modelos avanzados de inteligencia artificial desarrollados por OpenAI, como GPT-4, GPT-3, Codex y DALL·E, a través de la infraestructura confiable y escalable de Azure. Este servicio permite a las empresas integrar capacidades de procesamiento de lenguaje natural (NLP) y generación de contenido en sus aplicaciones.

Aprovechamos la capacidad de procesamiento en batch para poder enviar a analizar el contenido de los documentos de forma asíncrona, teniendo en cuenta que el procesamiento se realiza en los servidores de openAI el cual puede tardar hasta 24 horas:

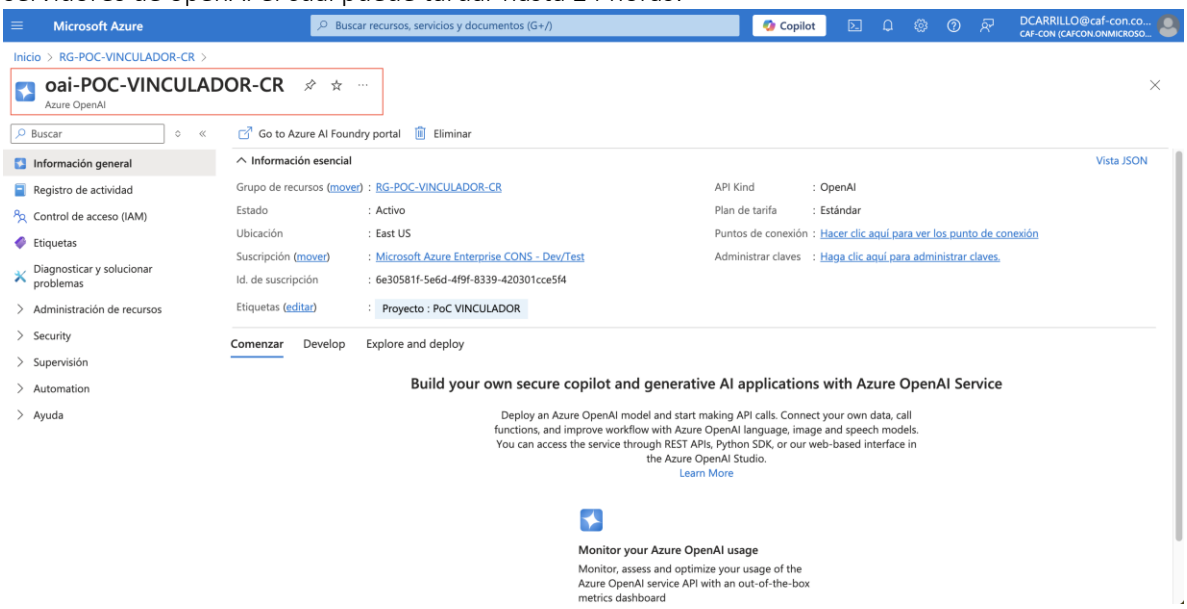

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

Azure databricks: Es una plataforma de análisis de datos basada en Apache Spark. Está diseñada para ayudar a las empresas a procesar, analizar y modelar grandes volúmenes de datos de manera colaborativa, combinando la ingeniería de datos, el análisis avanzado y el aprendizaje automático en un entorno unificado.

A través del notebook de databricks, realizamos la integración con tecnologías como blob storage, document intelligence, openAI y cosmosdb para el procesamiento de datos, envío modo batch al modelo de openAI y actualizar el estado final del análisis procesado.

El notebook de procesamiento se encuentra en la siguiente ruta

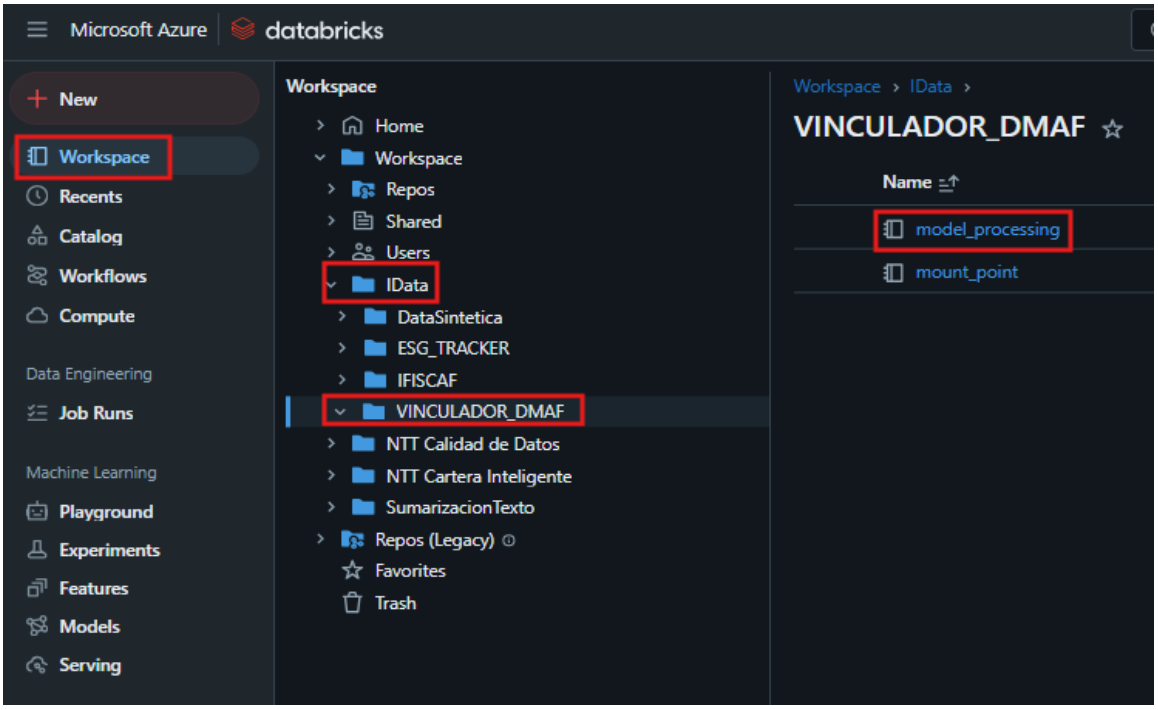

El paradigma de programación es funcional, entonces en la parte superior del notebook se pueden encontrar todas las funciones definidas para el procesamiento

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

Functions

12/5/2024 (<1s) 12 Python

```python
def getSubfoldersInFolder(specific_folder):
    subfolders = set()
    for blob in container_client.list_blobs(name_starts_with=specific_folder):
        remaining_path = blob.name[len(specific_folder):]
        if "/" in remaining_path:
            subfolder = remaining_path.split("/")[0]
            subfolders.add(subfolder)

    return subfolders
```

12/5/2024 (<1s) 13

```python
def getFilesInSubfolder(subfolder):
    files = {}
    for blob in container_client.list_blobs(name_starts_with=subfolder):
        remaining_path = blob.name[len(subfolder):]
        if remaining_path:
            file_name = remaining_path.split("/")[-1]
            file_url = f"{endpoint}/{container_client.container_name}/{blob.name}"
            files[file_name] = file_url

    return files
```

En la sección inferior se pueden visualizar las ejecuciones de todas las funciones previamente definidas incluyendo el llamado por batch a la API de OpenAI

Execution

12/5/2024 (<1s) 22

```python
try:
    allies_folders = list(getSubfoldersInFolder("allies/"))
    projects_folders = list(getSubfoldersInFolder("projects/"))

    json_batch_gpt_elements = []

    for ally in allies_folders:

        specific_subfolder_allies = f"allies/{ally}/"
        ally_files = getFilesInSubfolder(specific_subfolder_allies)
        ally_unique_file = list(ally_files.items())[0]
        ally_file_name = ally_unique_file[0]
        ally_file_url = ally_unique_file[1] + "?" + STORAGE_ACCOUNT_CONTAINER_SAS_TOKEN
        ally_file_content_json = pdf_to_json_with_text_and_tables(ally_file_url)

        for project in projects_folders:
            specific_subfolder_projects = f"projects/{project}/"
            projects_files = getFilesInSubfolder(specific_subfolder_projects)
            list_projects_files = list(projects_files.items())

            projects_text = ""

            for project_file in list_projects_files:
                project_file_url = project_file[1] + "?" + STORAGE_ACCOUNT_CONTAINER_SAS_TOKEN
                project_file_content_json = pdf_to_json_with_text_and_tables(project_file_url)
                projects_text += project_file_content_json

            system_prompt = """
            You are a precise and detail-oriented assistant responsible for evaluating whether a project's requirements for financing are satisfied in general.

            Your task is to:
            1. Analyze a predefined list of financing requirements.
            2. Compare them with detailed project information.
            3. Determine if the project meets all the requirements collectively.
            4. Extract the name of the country where the project will be executed from the Project Information.
```

4.1 Ambientes disponibles

El diagrama de arquitectura anterior (punto 3.0) fue implementado en único ambiente habilitado por el cliente.

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

4.2 Estrategia de logs y monitoreo

La estrategia de logs y monitoreo para la primera versión del sistema, lo estamos manejando a través de las diferentes opciones de monitoreo que nos provee cada tecnología de azure, los cuales serían los siguientes:

Azure web application: Para poder monitorear los logs, azure web application cuenta con la opción de "secuencia de registro" donde se visualiza los logs a medida que el backoffice es ejecutado.

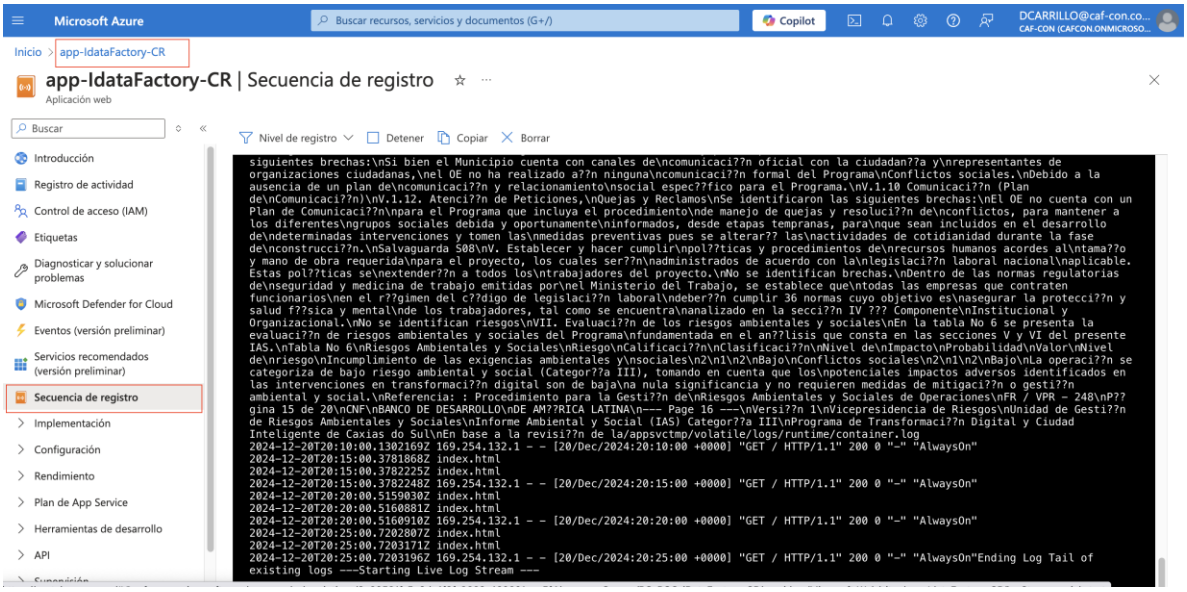

Azure functions: Cuenta con la opción de "secuencia de registro", dónde se puede habilitar la opción de "application insigths" para el monitoreo y visualización de los logs.

Azure data factory: Provee la opción de "monitor", dónde se puede visualizar las ejecuciones del pipeline, además, se pueden aplicar filtros por pipeline, fecha de ejecución, estado y otros filtros.

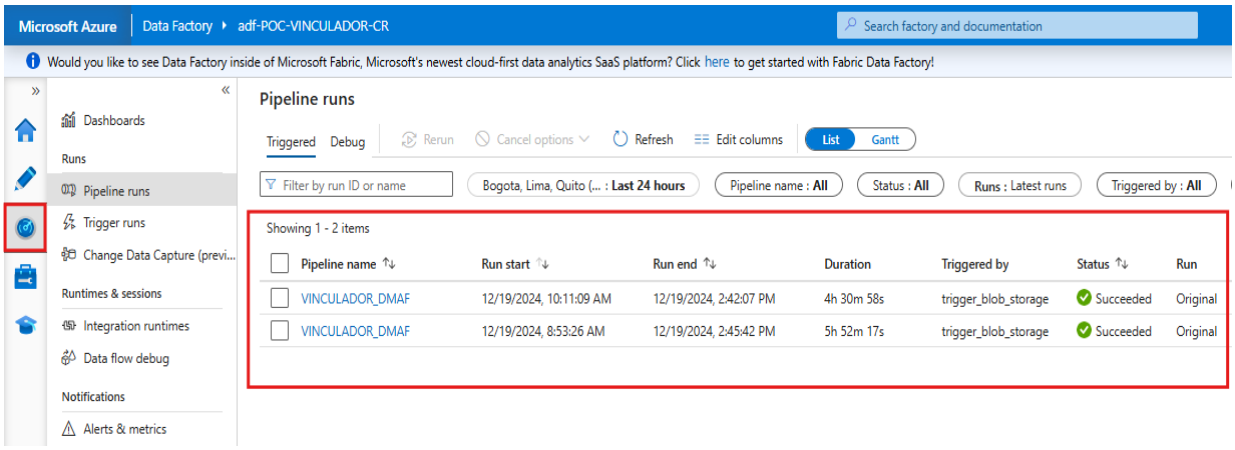

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

Azure databricks: Cuenta con la opción de poder visualizar los logs de cada ejecución en la terminal del notebook. Se ingresa a través del enlace atado a cada ejecución del pipeline desde Data Factory.

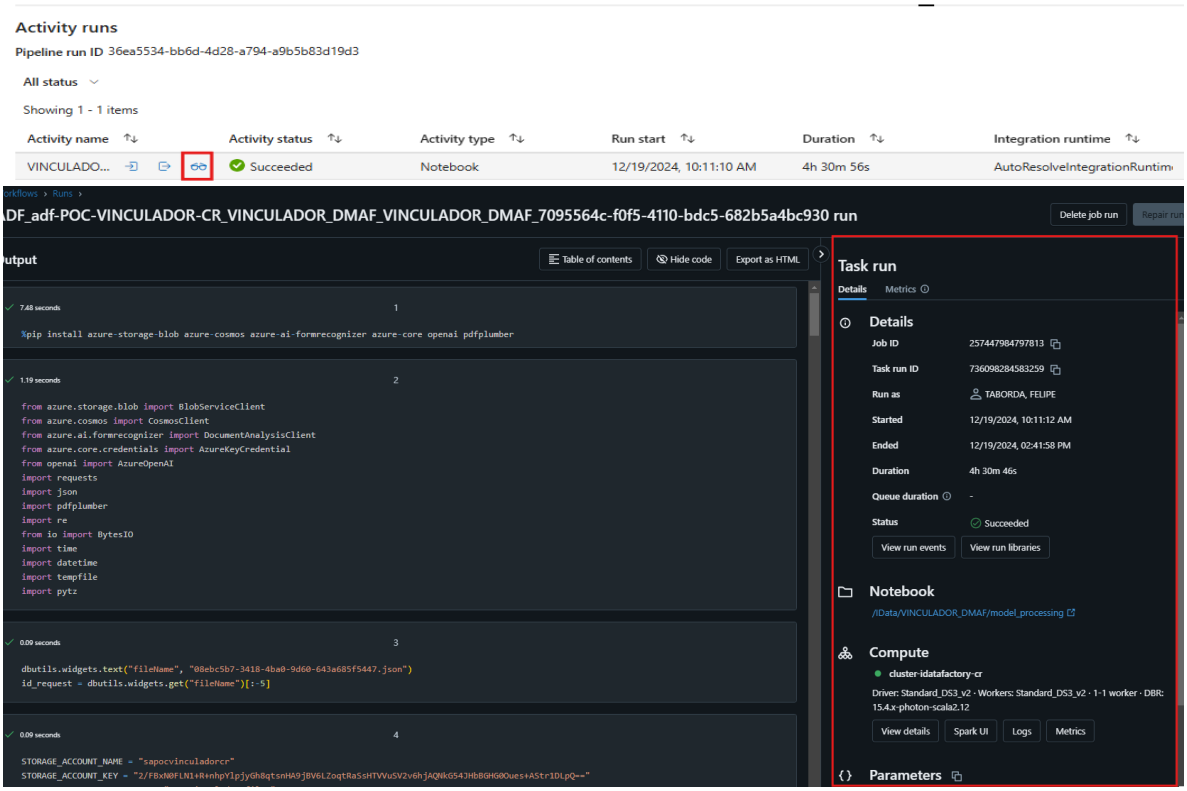

5 Azure DevOps

Se cuenta con un repositorio habilitado por el cliente, dónde se tienen los códigos fuente de cada iniciativa.

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

---Fin del documento---

USA *333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131*
USA *1240 W Peachtree St NW, Atlanta, GA 30309*
Colombia *Medellín - Calle 67 # 52-20 Torre A INT 3015*
Centroamérica y el Caribe *RD Santo Domingo - Av. Lope de Vega 19 10119*
Chile *Santiago - Camino El Alba 9500 Of 303*