iDATA
Advanced analytics for business

PRESENTA A

CAF
BANCO DE DESARROLLO
DE AMÉRICA LATINA

DOCUMENTO TÉCNICO Y DE ARQUITECTURA - VINCULADOR DMAF

Versión	Responsable	Modificación	Fecha
1.0.0	Dany Carrillo (IDATA)	Creación de documento	08/04/2025

Nombre del cliente	CAF (Corporación Andina de Fomento)
Nombre del proyecto	Vinculador DMAF
Responsable IDATA	Carlos Rene Trujillo (Data Science) Daniela Osorio Trujillo (Project Analyst) Gerardo Martin Orozco (Full Stack) Leonardo David Gonzales (Full Stack) Dany Daniel Carrillo Jara (Full Stack) Cristian Andres Vitery (Technical Leader)
Nombre del contacto del cliente	Braulio Salazar
Cargo	Technology Innovation Executive
Correo electrónico del contacto	bsalarzar@caf.com

USA *333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131*
USA *1240 W Peachtree St NW, Atlanta, GA 30309*
Colombia *Medellín - Calle 67 # 52-20 Torre A INT 3015*
Centroamérica y el Caribe *RD Santo Domingo - Av. Lope de Vega 19 10119*
Chile *Santiago - Camino El Alba 9500 Of 303*

Contenido

1 Introducción 4
2 Objetivos 4
2.1 Generales 4
2.2 Específicos 4
3 Descripción del proyecto 4
3.1 Descripción 4
3.2 Requerimientos 4
4 Arquitectura de la solución 5
4.1 Diagrama físico de arquitectura 5
4.1.1 Descripción de componentes 5
4.1.2 Diagrama físico de arquitectura transversales . **¡Error! Marcador no definido.**
4.1.3 Descripción de componentes transversales 12
4.2 Ambientes disponibles 15
4.3 Estrategia de logs y monitoreo 15
5 Azure DevOps 18

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

1 Introducción

Este documento tiene como objetivo dar a conocer la arquitectura diseñada para la iniciativa Vinculador.

2 Objetivos

2.0 Generales

El objetivo general de este documento es proveer información relevante sobre la arquitectura y el diseño de la solución desarrollada para conocer diferentes aspectos del sistema.

2.1 Específicos

- Describir detalladamente la arquitectura a nivel de servicios usados.
- Brindar una descripción funcional de los componentes de la arquitectura propuesta.
- Exponer la distribución de los diferentes componentes para ambientes de desarrollo y producción dentro de los diferentes componentes Microsoft Azure propuestos.
- Detallar los elementos de seguridad para cada uno de los servicios involucrados en la arquitectura.
- Definir la estrategia de integración y despliegue continuo.

3 Descripción del proyecto

3.0 Descripción

El proyecto vinculador DMAF, se centra en identificar de forma automática cuales proyectos son candidatos para cofinanciar por los diferentes aliados, además, reduce considerablemente el tiempo de análisis.

3.1 Requerimientos

- El cliente tiene la necesidad de cargar documentos de proyectos y aliados existentes o nuevos.
- El cliente tiene la necesidad de visualizar los documentos de proyectos y aliados que ya fueron cargar.
- El cliente tiene la necesidad de poder eliminar los documentos de proyectos y aliados.
- El cliente tiene la necesidad de procesar análisis entre los diferentes proyectos y aliados existentes, para poder conocer si los proyectos y aliados cumplen con las condiciones indicados por el negocio.

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

4 Arquitectura de la solución

El esquema de arquitectura que se presenta a continuación muestra un alcance inicial de referencia que cubre las necesidades actuales de los requerimientos de arquitectura con buenas prácticas, escalabilidad y costos.

4.0 Diagrama físico de arquitectura

El siguiente esquema representa la arquitectura implementada para el desarrollo del proyecto:

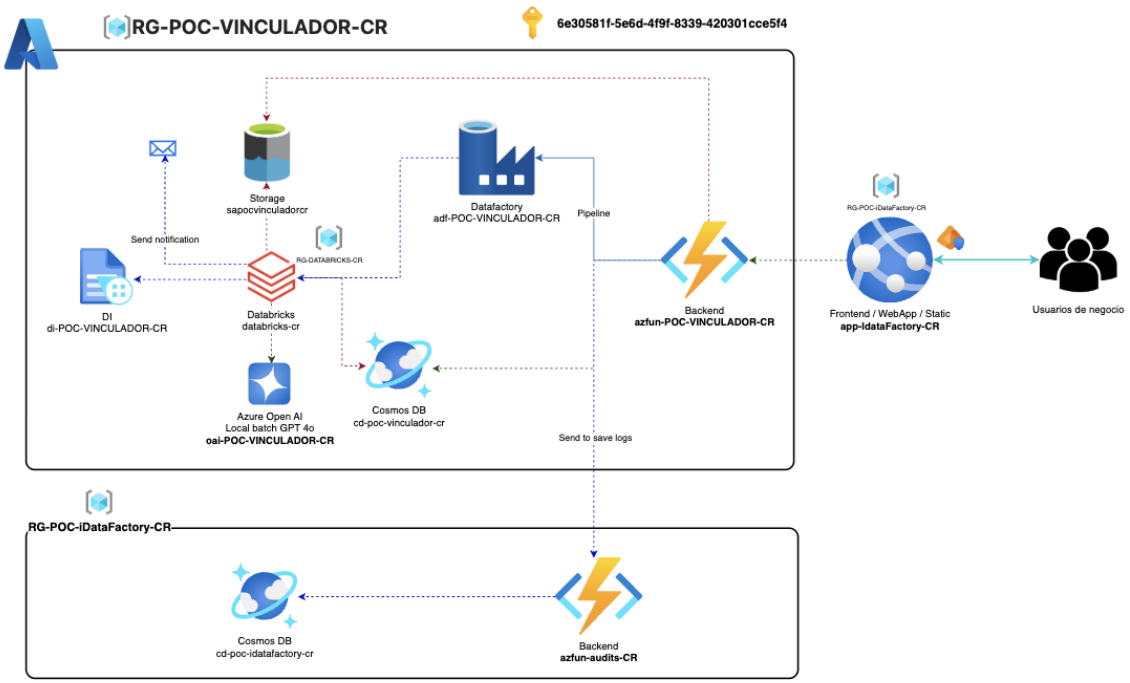

4.0.0 Descripción de componentes

Azure web application: Es un servicio de plataforma como servicio (PaaS), permite implementar, alojar y escalar aplicaciones web de manera sencilla y eficiente. Está diseñado para admitir múltiples lenguajes, marcos y entornos, incluyendo .NET, Java, Python, PHP, Node.js y Ruby.

Estamos utilizando una web app para poder alojar el backoffice que contiene todas las iniciativas, debido a su simplicidad a la hora de crear aplicaciones web dinámicas con una escalabilidad global.

Enlace del portal: https://app-idatafactory-cr.azurewebsites.net/

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

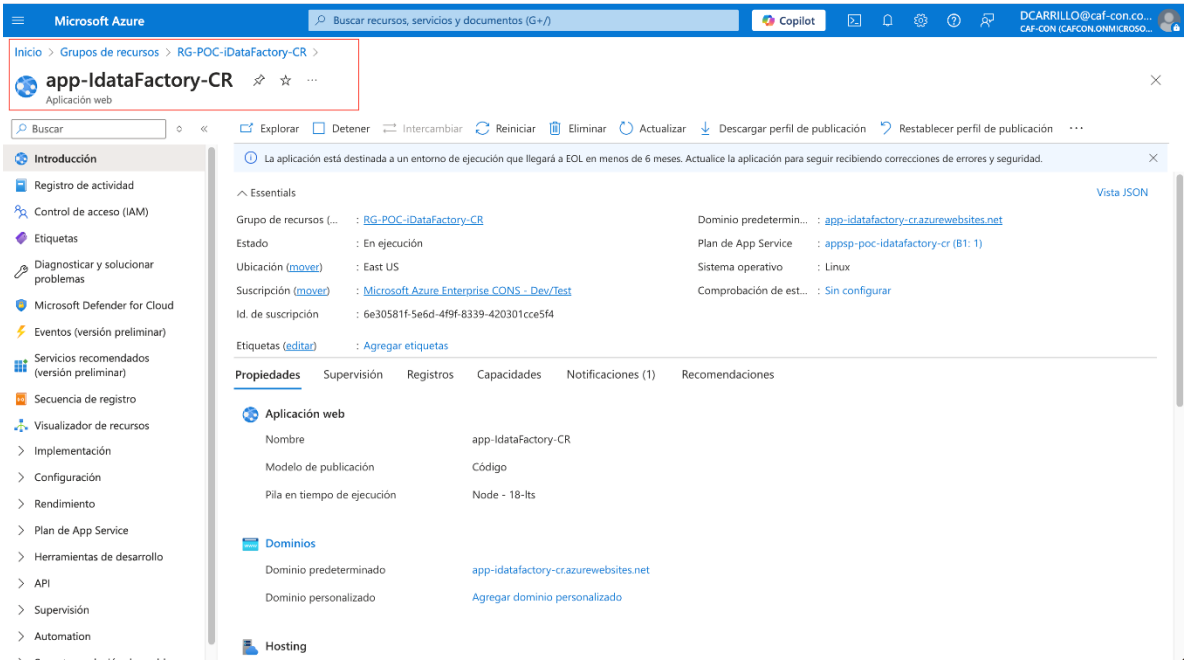

Azure functions: Es un servicio de **computación sin servidor** (serverless), diseñado para ejecutar pequeñas piezas de código, conocidas como funciones, en respuesta a eventos. Es ideal para ejecutar tareas ligeras y de corta duración sin necesidad de gestionar servidores o infraestructura subyacente.

Aprovechamos el potencial de los serverless con azure functions para desarrollar los servicios REST que permitan subir documentos hacia un contenedor, listar directorios y documentos de un contenedor, eliminar documentos, enviar a procesar análisis de proyectos y aliados:

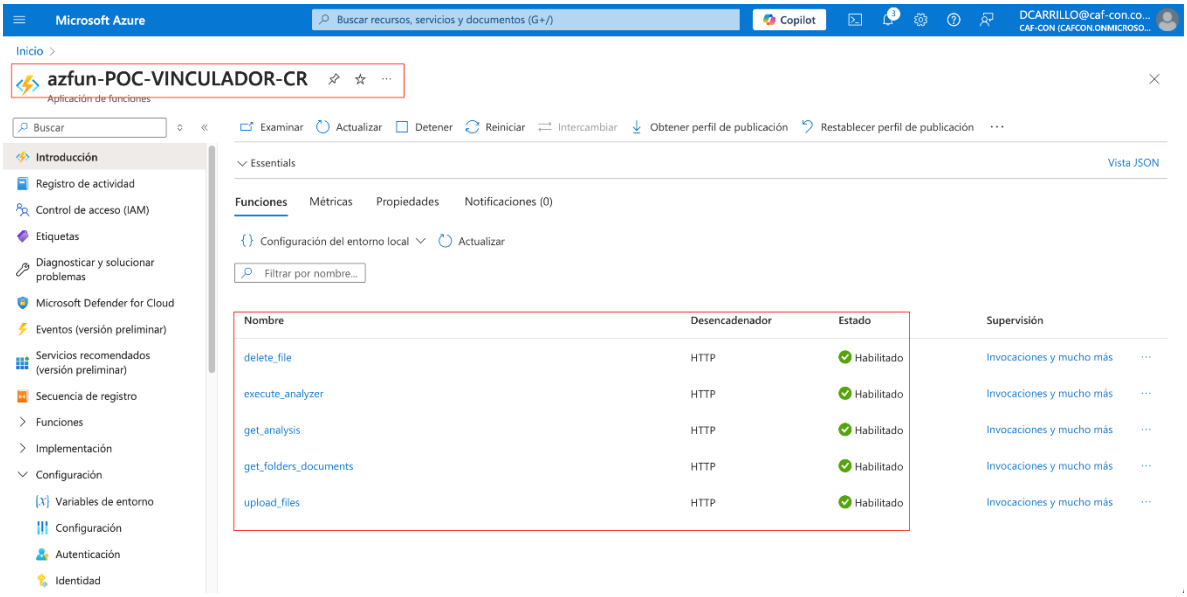

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

Azure cosmosdb: Es un servicio de base de datos NoSQL distribuido globalmente. Está diseñado para ser altamente disponible, escalable y rápido, ofreciendo compatibilidad con múltiples modelos de datos (documentos, clave-valor, columnares y grafos) y soporte para APIs populares como MongoDB, Cassandra, Gremlin, Table y Core (SQL).

En la arquitectura nos permite gestionar el proceso de análisis de proyectos y aliados de forma asíncrona, ya que se crea una petición para luego ser actualizado cuando termine el proceso de análisis:

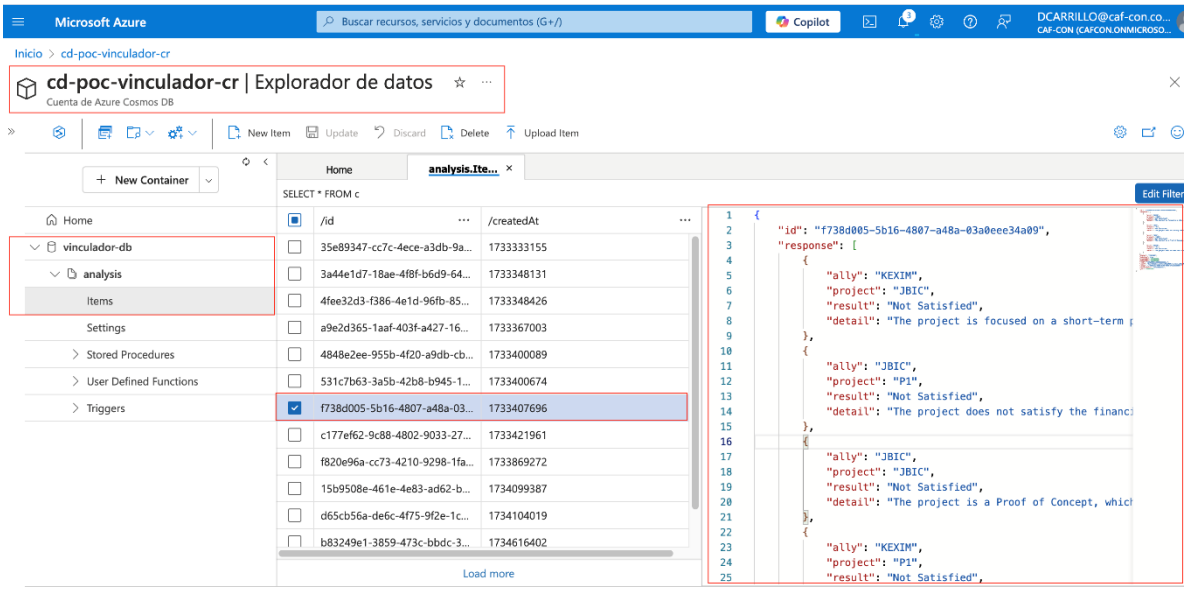

Azure blob storage: Es un servicio de almacenamiento de objetos en la nube. Está diseñado para almacenar grandes cantidades de datos no estructurados, como documentos, imágenes, videos, copias de seguridad, registros, y más.

Permite almacenar los documentos de proyectos y aliados, almacena los documentos de tipo JSONL para que luego sean enviados a openAI en modo batch, además, aprovechamos el blob trigger para poder enviar un evento hacia data factory:

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

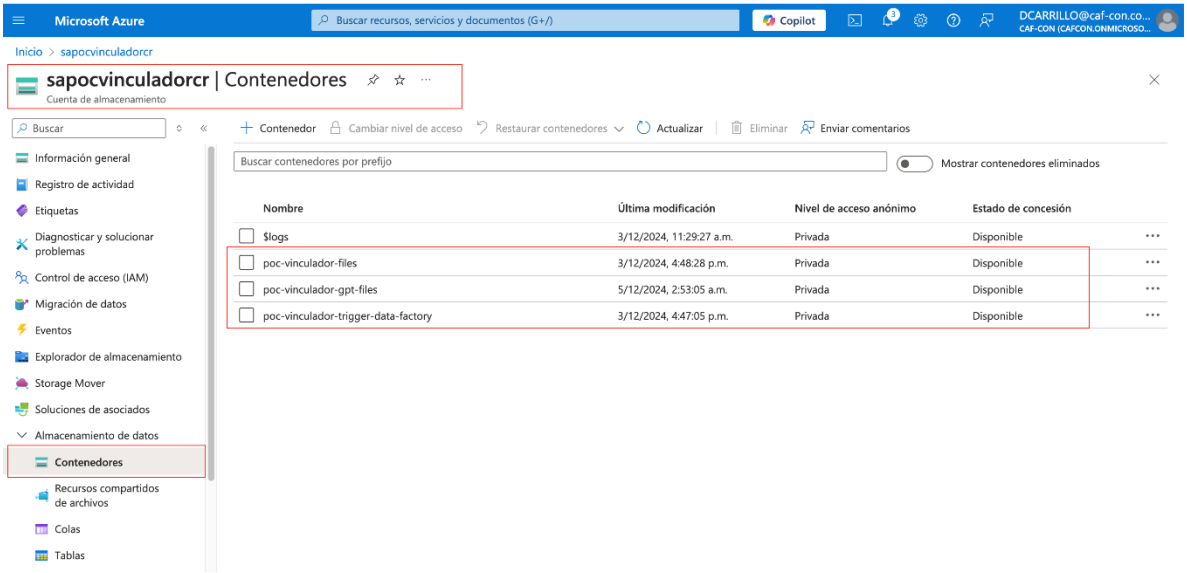

Azure data factory: Es un servicio de integración de datos en la nube. Es una herramienta que permite mover, transformar y orquestar grandes volúmenes de datos desde diversas fuentes hacia destinos definidos, facilitando la creación de flujos de trabajo de integración de datos (ETL/ELT).

En la arquitectura permite realizar una conexión hacia un notebook de databricks a través de un pipeline, el cual es ejecutado con un blob trigger cada vez que llegue un documento al contenedor, cuando el pipeline es ejecutado se envían los parametros necesarios a databricks para que siga el flujo:

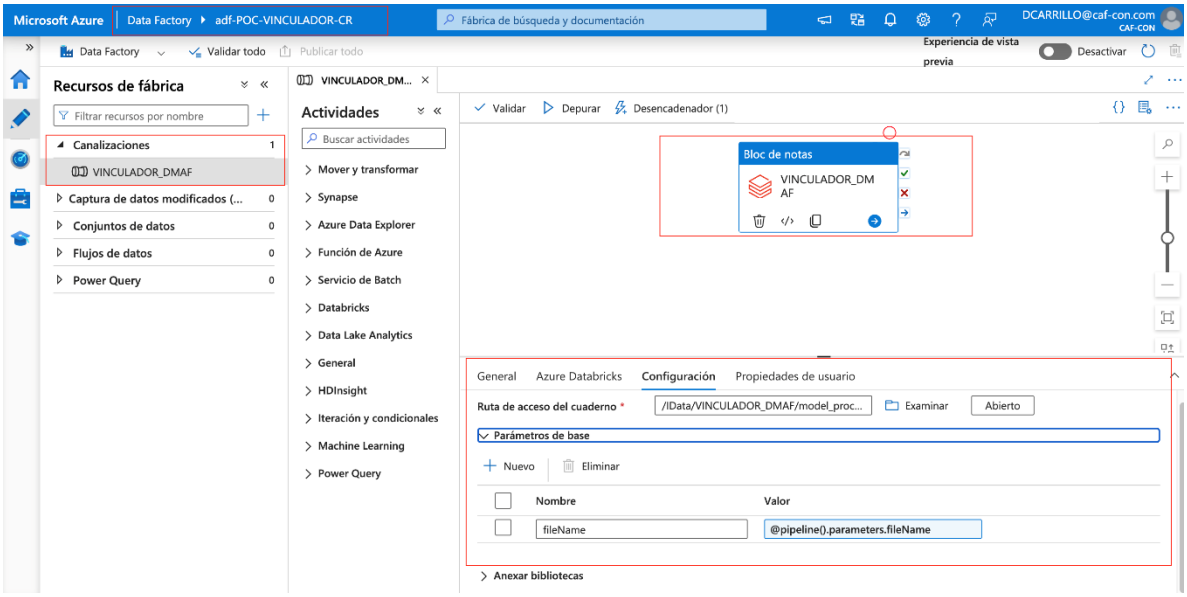

Azure document intelligence: Es un servicio de inteligencia artificial diseñado para extraer información estructurada y procesable de documentos no estructurados, como formularios,

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

facturas, recibos y contratos. Utiliza capacidades avanzadas de machine learning para analizar y comprender documentos de manera eficiente.

En la arquitectura, permite extraer el contenido de los documentos de todos los proyectos y aliados de forma fácil:

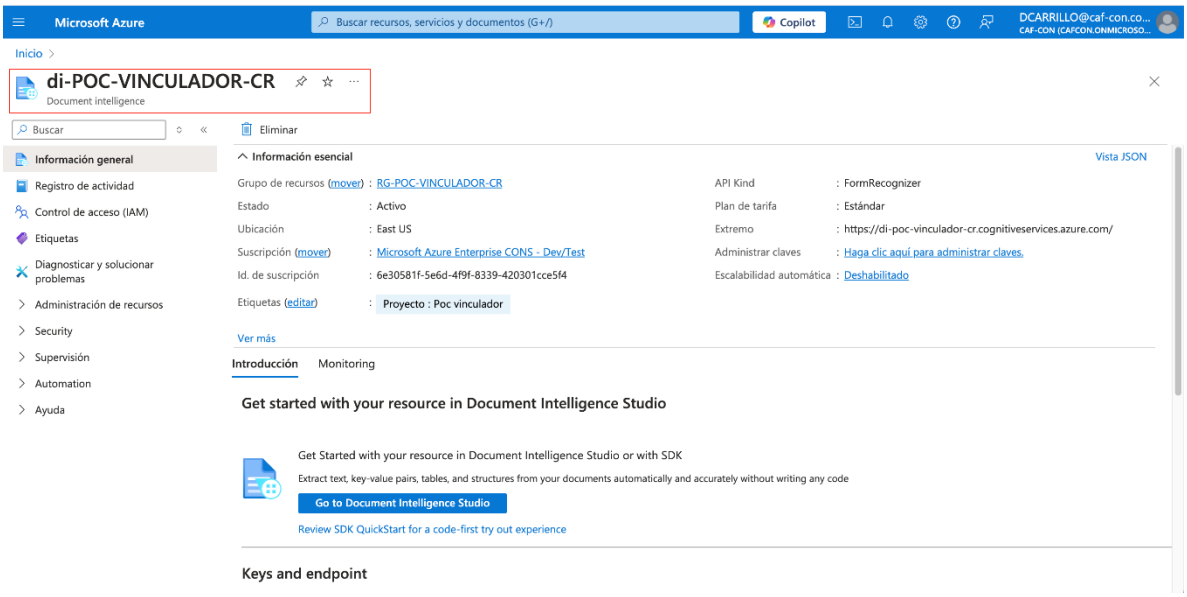

Azure openAI: Es un servicio que proporciona acceso a los modelos avanzados de inteligencia artificial desarrollados por OpenAI, como GPT-4, GPT-3, Codex y DALL·E, a través de la infraestructura confiable y escalable de Azure. Este servicio permite a las empresas integrar capacidades de procesamiento de lenguaje natural (NLP) y generación de contenido en sus aplicaciones.

Aprovechamos la capacidad de procesamiento en batch para poder enviar a analizar el contenido de los documentos de forma asíncrona, teniendo en cuenta que el procesamiento se realiza en los servidores de openAI el cual puede tardar hasta 24 horas:

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

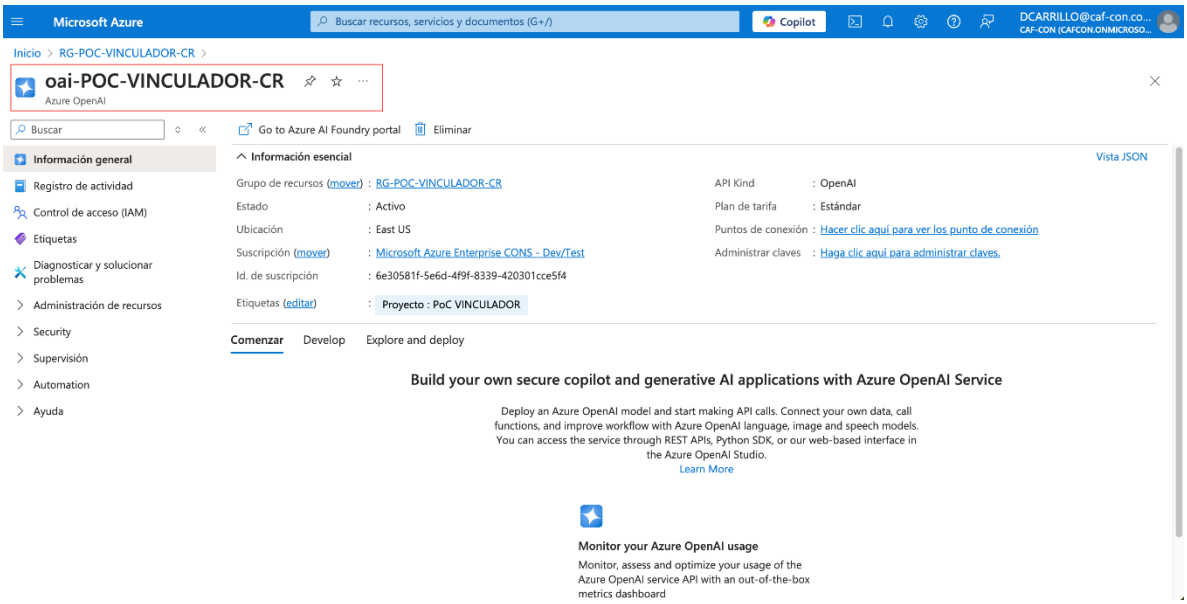

Azure databricks: Es una plataforma de análisis de datos basada en Apache Spark. Está diseñada para ayudar a las empresas a procesar, analizar y modelar grandes volúmenes de datos de manera colaborativa, combinando la ingeniería de datos, el análisis avanzado y el aprendizaje automático en un entorno unificado.

A través del notebook de databricks, realizamos la integración con tecnologías como blob storage, document intelligence, openAI y cosmosdb para el procesamiento de datos, envío modo batch al modelo de openAI y actualizar el estado final del análisis procesado.

El notebook de procesamiento se encuentra en la siguiente ruta

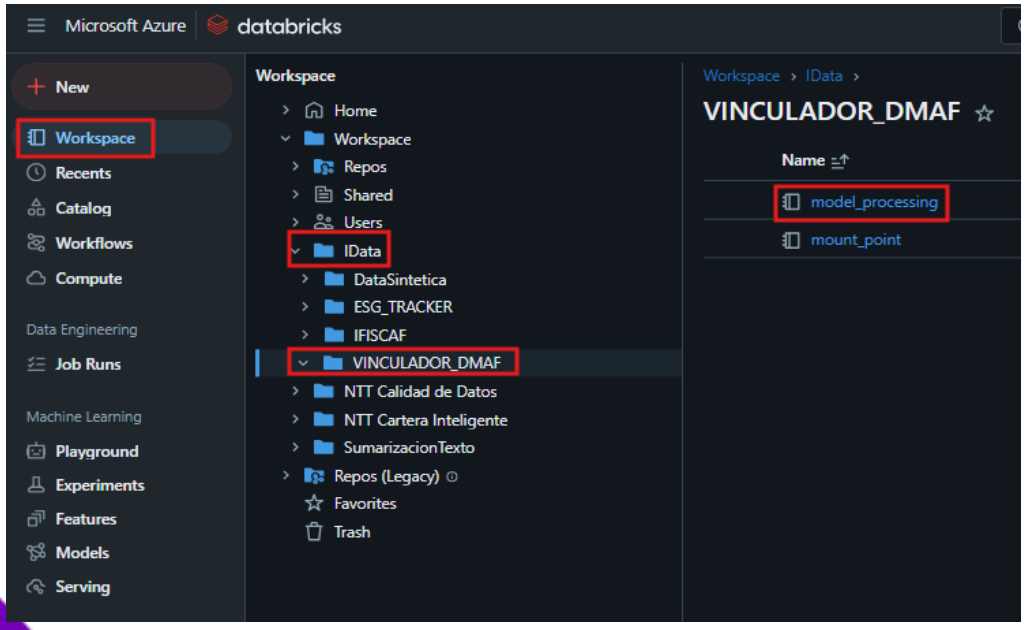

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

El paradigma de programación es funcional, entonces en la parte superior del notebook se pueden encontrar todas las funciones definidas para el procesamiento

Functions

12/5/2024 (<1s) 12 Python

```python
def getSubfoldersInFolder(specific_folder):
    subfolders = set()
    for blob in container_client.list_blobs(name_starts_with=specific_folder):
        remaining_path = blob.name[len(specific_folder):]
        if "/" in remaining_path:
            subfolder = remaining_path.split("/")[0]
            subfolders.add(subfolder)

    return subfolders
```

12/5/2024 (<1s) 13

```python
def getFilesInSubfolder(subfolder):
    files = {}
    for blob in container_client.list_blobs(name_starts_with=subfolder):
        remaining_path = blob.name[len(subfolder):]
        if remaining_path:
            file_name = remaining_path.split("/")[-1]
            file_url = f"{endpoint}/{container_client.container_name}/{blob.name}"
            files[file_name] = file_url

    return files
```

En la sección inferior se pueden visualizar las ejecuciones de todas las funciones previamente definidas incluyendo el llamado por batch a la API de OpenAI

Execution

12/5/2024 (<1s) 22

```python
try:
    allies_folders = list(getSubfoldersInFolder("allies/"))
    projects_folders = list(getSubfoldersInFolder("projects/"))

    json_batch_gpt_elements = []

    for ally in allies_folders:

        specific_subfolder_allies = f"allies/{ally}/"
        ally_files = getFilesInSubfolder(specific_subfolder_allies)
        ally_unique_file = list(ally_files.items())[0]
        ally_file_name = ally_unique_file[0]
        ally_file_url = ally_unique_file[1] + "?" + STORAGE_ACCOUNT_CONTAINER_SAS_TOKEN
        ally_file_content_json = pdf_to_json_with_text_and_tables(ally_file_url)

        for project in projects_folders:
            specific_subfolder_projects = f"projects/{project}/"
            projects_files = getFilesInSubfolder(specific_subfolder_projects)
            list_projects_files = list(projects_files.items())

            projects_text = ""

            for project_file in list_projects_files:
                project_file_url = project_file[1] + "?" + STORAGE_ACCOUNT_CONTAINER_SAS_TOKEN
                project_file_content_json = pdf_to_json_with_text_and_tables(project_file_url)
                projects_text += project_file_content_json

            system_prompt = """
            You are a precise and detail-oriented assistant responsible for evaluating whether a project's requirements for financing are satisfied in general.

            Your task is to:
            1. Analyze a predefined list of financing requirements.
            2. Compare them with detailed project information.
            3. Determine if the project meets all the requirements collectively.
            4. Extract the name of the country where the project will be executed from the Project Information.
```


USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

4.1 Diagrama físico de arquitectura transversal(notificaciones)

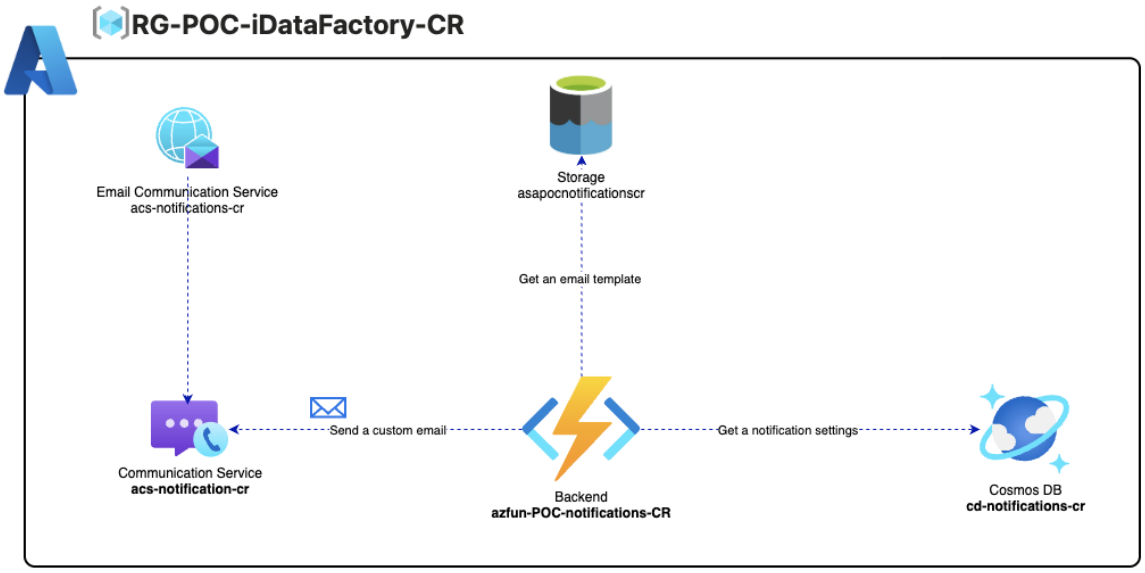

4.1.0 Descripción de componentes transversales(notificaciones)

La arquitectura transversal de notificaciones tiene como responsabilidad gestionar las notificaciones. Inicialmente contamos con notificaciones por correo electrónico los cuales pueden ser enviados desde cualquier punto a lo largo del ecosistema.

Para cubrir dicha necesidad, contamos con los siguientes componentes ya mostrados en el diseño de arquitectura:

Azure cosmos DB(cd-notifications-cr): Almacena todas las configuraciones relacionadas con las diferentes notificaciones, inicialmente contamos con notificaciones por correo electrónico, dónde por cada iniciativa se tienen configurados los correos electrónicos de destino, copia, copia oculta, asunto, tipo de correo a enviar y ruta de la plantilla de correo.

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

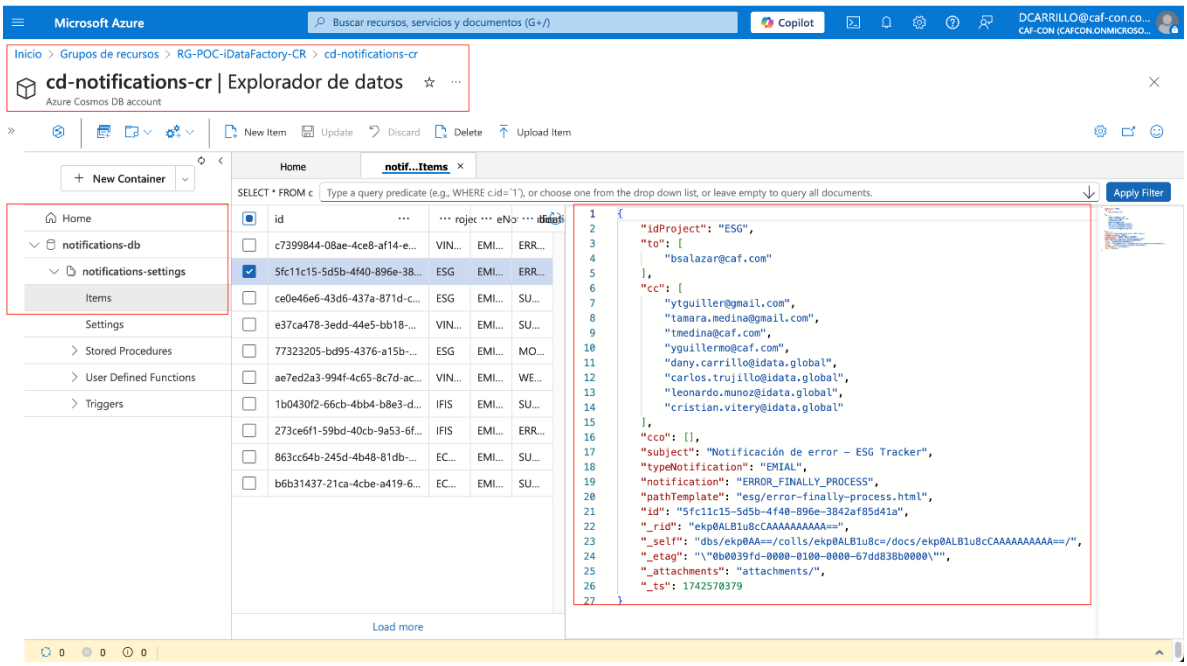

Azure functions(azfunc-POC-notifications-CR): Tiene como responsabilidad gestionar el envío de notificaciones, inicialmente gestiona el enviar el correo electrónico, para ello, a través del atributo “idProject” se obtiene la configuración almacenada en la base de datos, dónde se encuentra el “pathTemplate” que corresponde a la ruta de blob storage donde se encuentra almacenado la plantilla de correo. Reemplaza los valores dinámicos de la plantilla de correo y realiza el envío de correo electrónico a los destinatarios configurados en la base de datos.

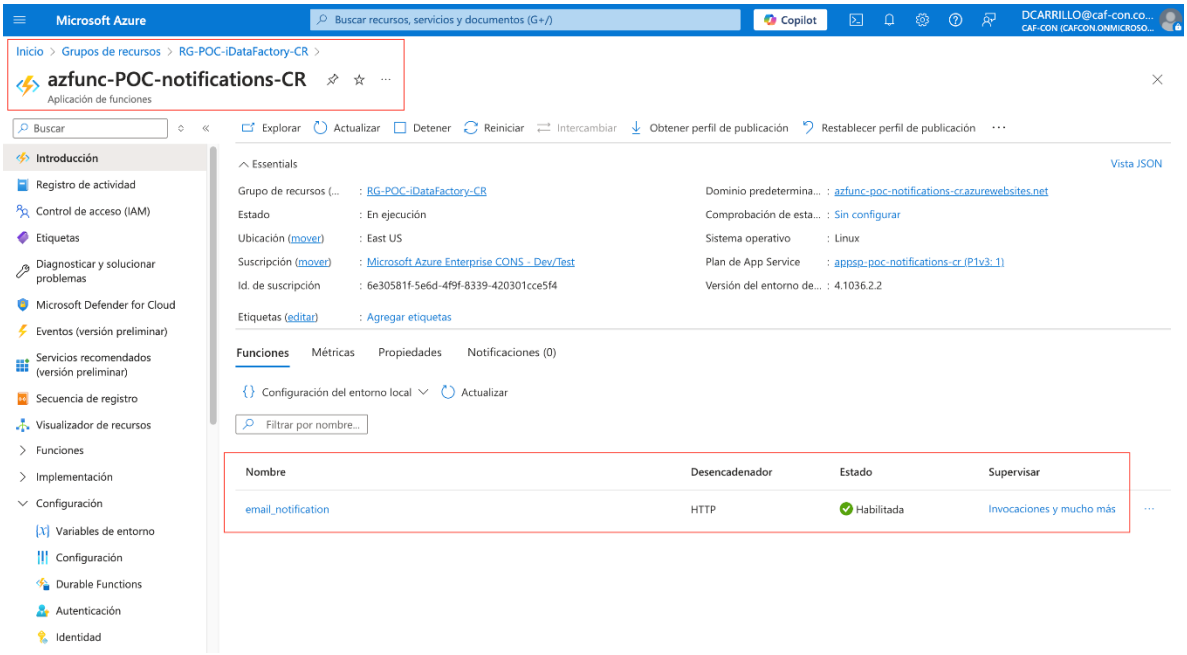

USA *333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131*
USA *1240 W Peachtree St NW, Atlanta, GA 30309*
Colombia *Medellín - Calle 67 # 52-20 Torre A INT 3015*
Centroamérica y el Caribe *RD Santo Domingo - Av. Lope de Vega 19 10119*
Chile *Santiago - Camino El Alba 9500 Of 303*

Azure blob storage(asapocnotificationscr): Es Almacena las diferentes plantillas de correos por cada iniciativa, además, almacena los logos que se muestran en cada plantilla de correo.

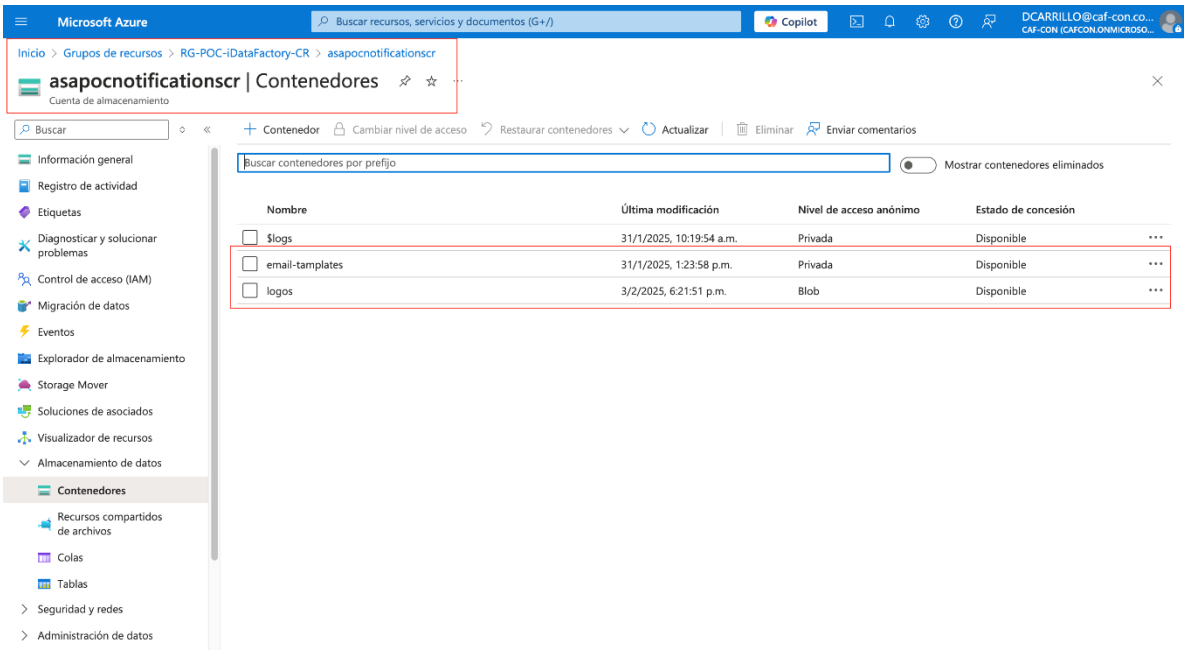

Azure communication services(acs-notification-cr): Es un conjunto de servicios en la nube de Microsoft Azure que permite integrar **funcionalidades de comunicación** (como llamadas de voz, video, chat, SMS y correo electrónico) directamente en aplicaciones web, móviles o de escritorio.

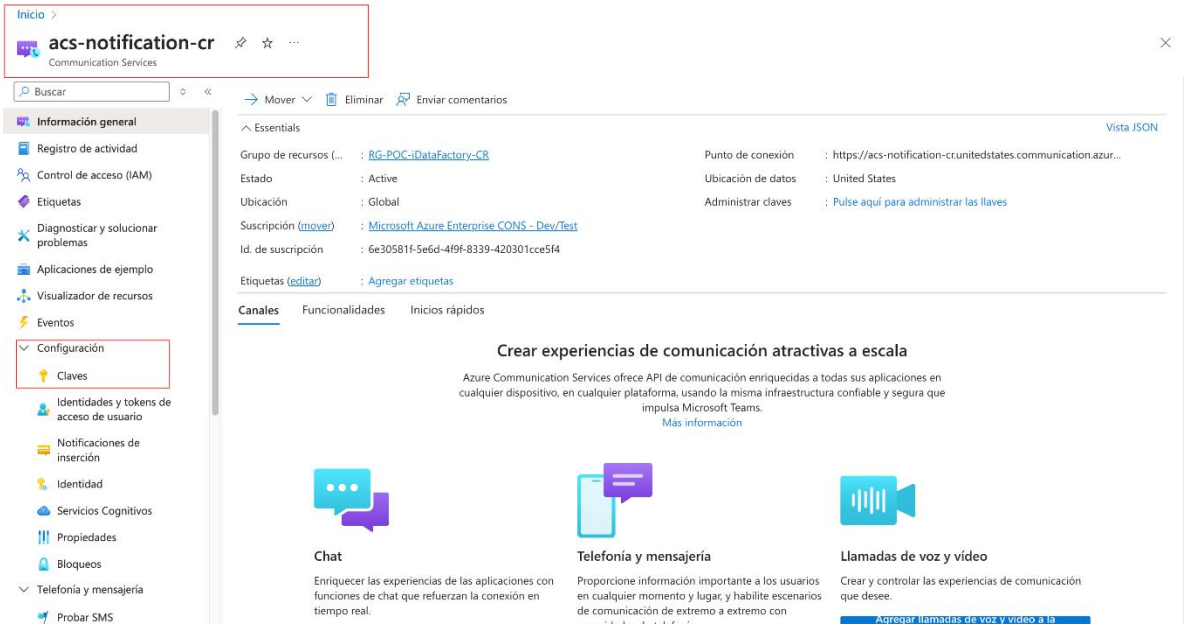

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

Azure email communication service(acs-notifications-cr): Es una funcionalidad dentro de **Azure Communication Services** que permite **enviar correos electrónicos** desde tus aplicaciones usando la infraestructura confiable de Microsoft. Está diseñado para manejar **emails transaccionales**, notificaciones y comunicaciones automatizadas de forma segura, escalable y con alta entrega.

Permite personalizar y gestionar los dominios que serán usados como remitente de los correos electrónicos.

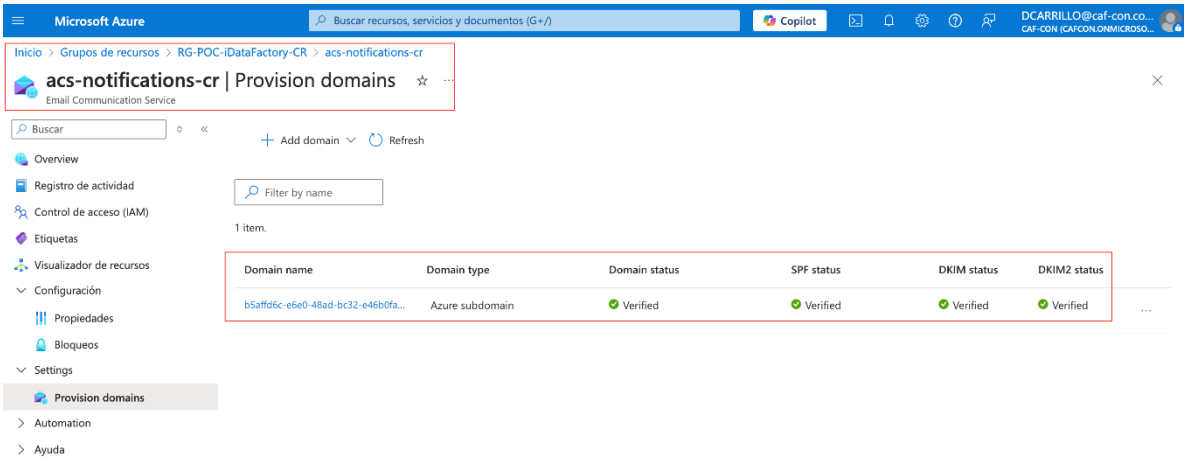

4.2 Ambientes disponibles

El diagrama de arquitectura anterior (punto 3.0) fue implementado en único ambiente habilitado por el cliente.

4.3 Estrategia de logs y monitoreo

La estrategia de logs y monitoreo, lo estamos manejando a través de las diferentes opciones de monitoreo que nos provee cada tecnología de azure, los cuales serían los siguientes:

Azure web application: Para poder monitorear los logs, azure web application cuenta con la opción de “secuencia de registro” donde se visualiza los logs a medida que el backoffice es ejecutado.

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

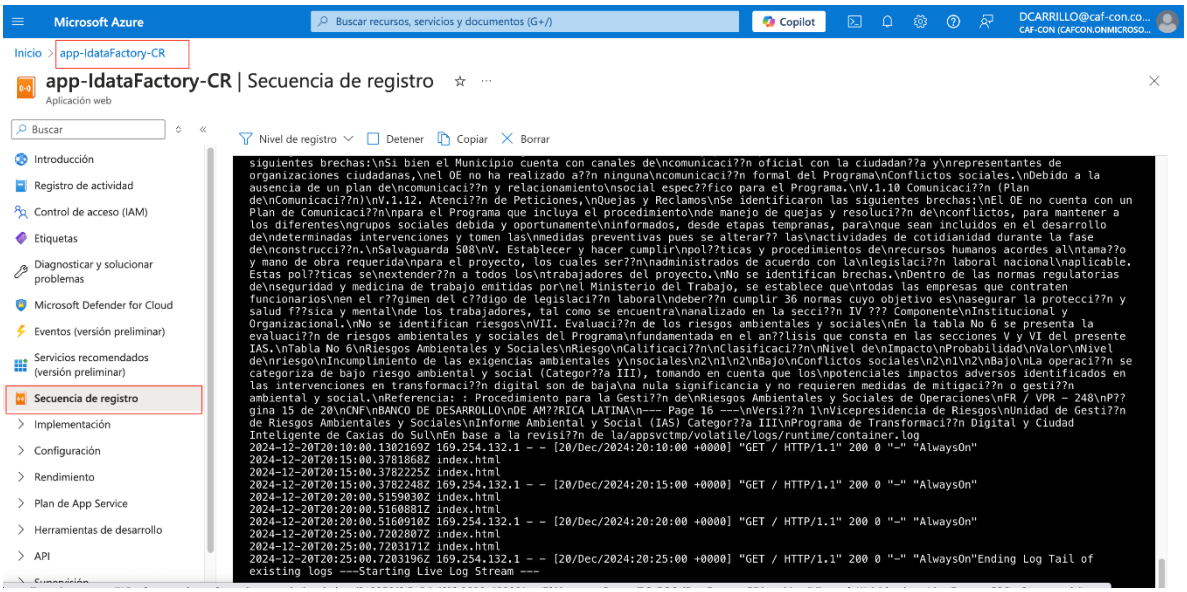

Azure functions: Cuenta con la opción de "secuencia de registro", dónde se puede habilitar la opción de "application insigths" para el monitoreo y visualización de los logs.

Azure data factory: Provee la opción de "monitor", dónde se puede visualizar las ejecuciones del pipeline, además, se pueden aplicar filtros por pipeline, fecha de ejecución, estado y otros filtros.

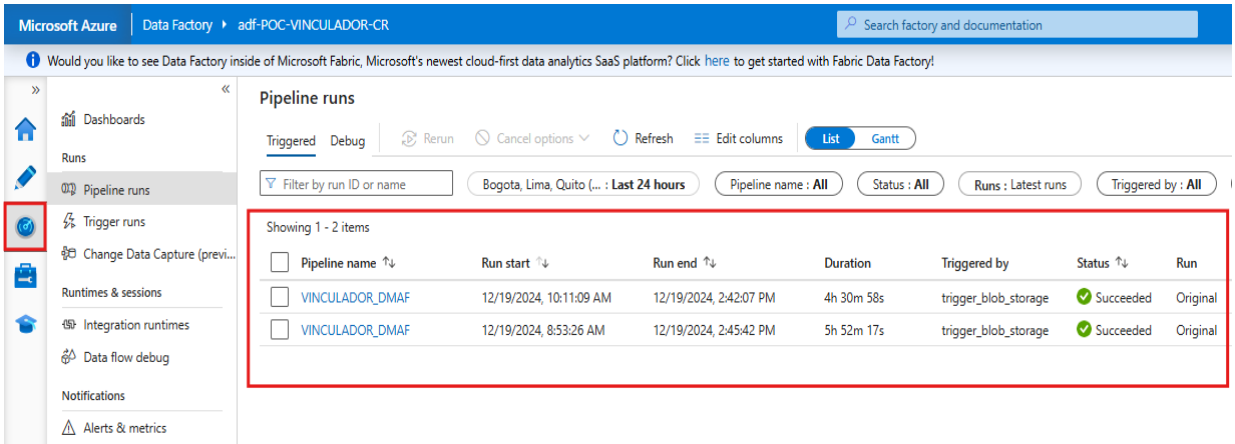

Azure databricks: Cuenta con la opción de poder visualizar los logs de cada ejecución en la terminal del notebook. Se ingresa a través del enlace atado a cada ejecución del pipeline desde Data Factory.

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

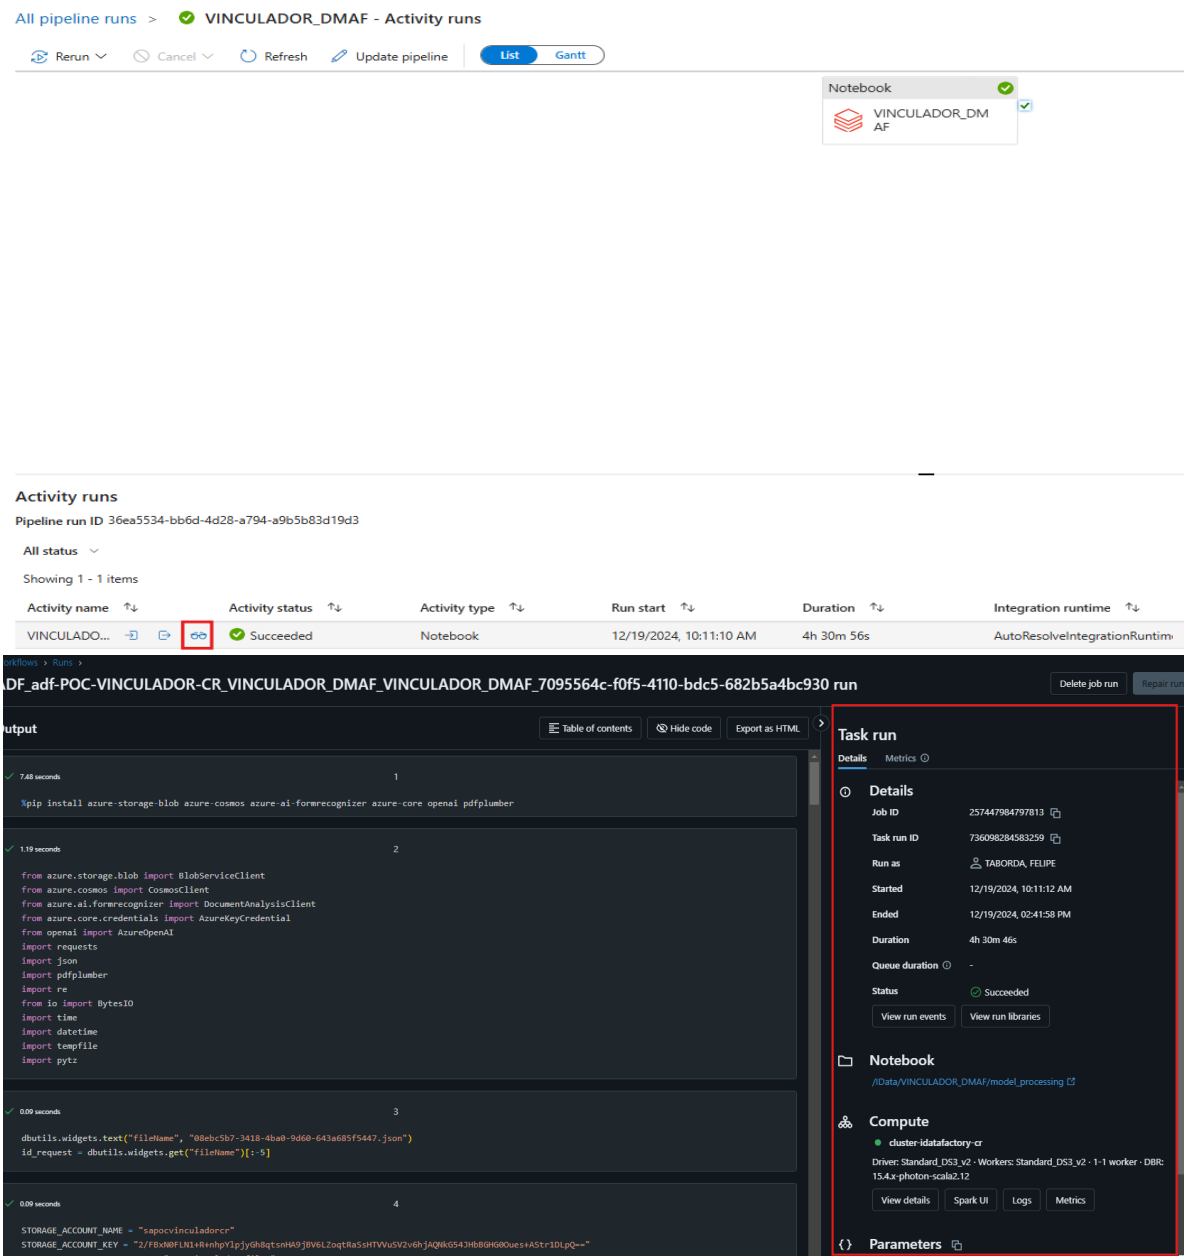

Además, dentro de la arquitectura tenemos un azure function que expone una API transversal que nos permite gestionar la auditoria de nuestra aplicación, para lograr dicha gestión se cuenta con los siguientes componentes

Azure functions(azfunc-audits-CR): Tiene la responsabilidad de permitir la gestión de la autoría a través de los diferentes API's. El registro de la auditoría se realiza de manera transversal debido a que la API se integra en los diferentes puntos del ecosistema backend(azure functions, databricks).

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303

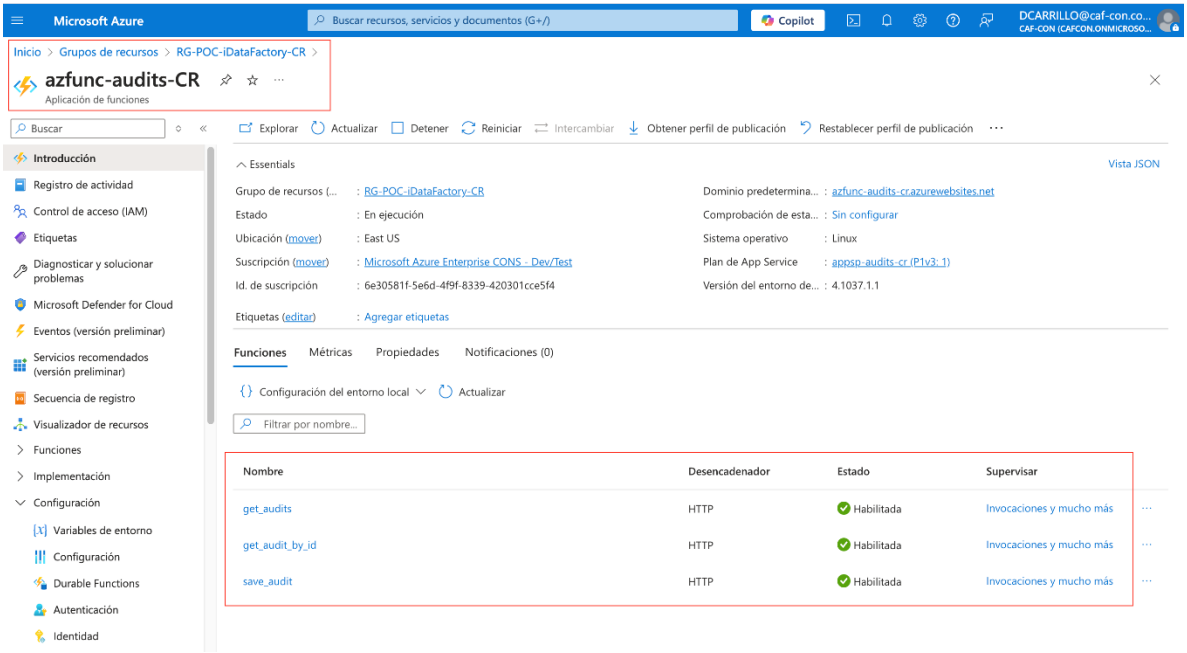

Azure cosmos DB(cd-poc-idatafactory-cr): Almacena la auditoría para facilitar la disponibilidad y gestión.

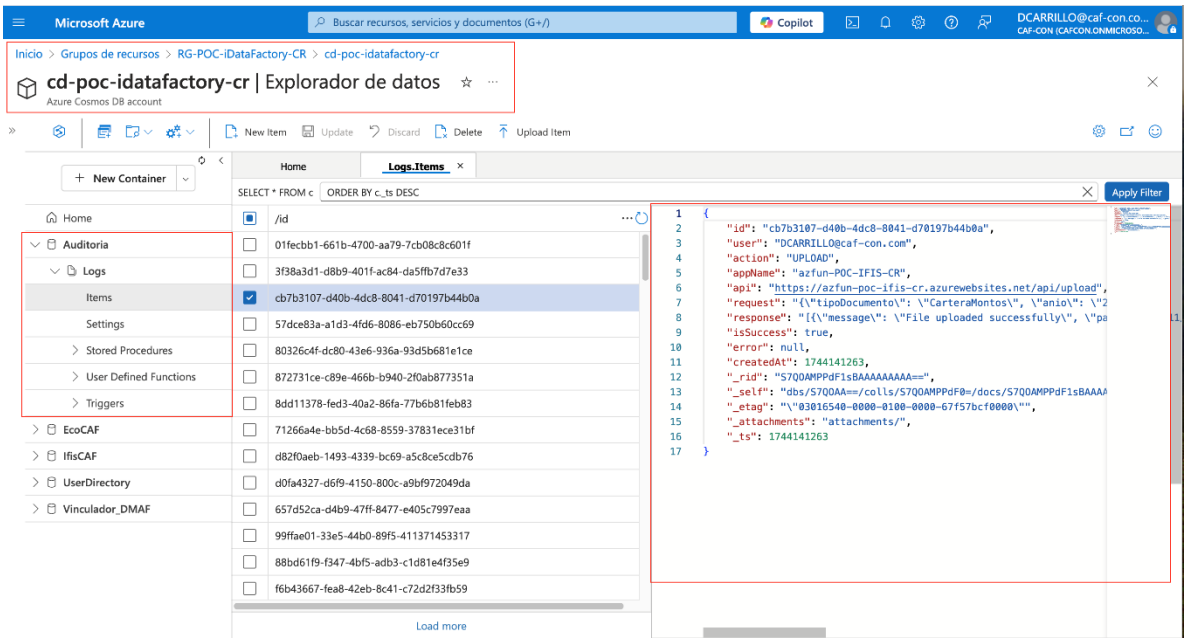

5 Azure DevOps

Se cuenta con un repositorio habilitado por el cliente, dónde se tienen los códigos fuente de cada iniciativa.

---Fin del documento---

USA 333 S. E. 2nd Avenue, Suite 2000, Miami, FL 33131
USA 1240 W Peachtree St NW, Atlanta, GA 30309
Colombia Medellín - Calle 67 # 52-20 Torre A INT 3015
Centroamérica y el Caribe RD Santo Domingo - Av. Lope de Vega 19 10119
Chile Santiago - Camino El Alba 9500 Of 303